

第六章：参数估计

张伟平

第六章：参数估计

6.1	点估计	2
6.1.1	矩估计方法	2
6.1.2	最大似然估计方法	7
6.1.3	点估计的优良准则	20

参数估计问题:

- 总体: $X \sim f_{\theta}(x), f$ 形式已知, $\theta = (\theta_1, \dots, \theta_k)$ 为未知参数
- 样本: X_1, \dots, X_n

利用样本对参数 θ 的作出估计或估计它们的某个已知函数 $g(\theta)$.

- **点估计**: 用样本的一个函数 $T(X_1, \dots, X_n)$ 去估计 $g(\theta)$
- **区间估计**: 用一个区间 (区域) 去估计 $g(\theta)$

6.1 点估计

根据样本 X_1, \dots, X_n 来估计参数 θ , 就是要构造适当的统计量 $\hat{\theta} = \hat{\theta}(X_1, \dots, X_n)$. 当有了样本 X_1, \dots, X_n 的值后, 就代入 $\hat{\theta} = \hat{\theta}(X_1, \dots, X_n)$ 中算出一个值, 用来作为 θ 的估计值. 为这样特定目的而构造的统计量 $\hat{\theta}$ 叫做 θ 的**估计量**. 由于参数 θ 是数轴上的一个点, 用 $\hat{\theta}$ 估计 θ , 等于用一个点去估计另一个点, 所以这样的估计叫做**点估计**.

求点估计的方法有多种, 下面介绍两种点估计方法:

6.1.1 矩估计方法

矩方法追溯到 19 世纪的**Karl Pearson**. 矩方法是基于一种简单的“替换”思想建立起来的一种估计方法. 其基本思想是用样本矩估计总体矩. 由大数律, 如果未知参数和总体的某个 (些) 矩有关系, 我们很自然的来构造未知参数的估计。

回忆一下以前关于矩的记法:

$$\text{样本}k\text{阶矩: } a_k = \frac{1}{n} \sum_{i=1}^n X_i^k \quad m_k = \frac{1}{n} \sum_{i=1}^n (X_i - \bar{X})^k$$

$$\text{总体}k\text{阶矩: } \alpha_k = EX^k \quad \mu_k = E(X - EX)^k$$

因此在 k 阶矩存在的情况下, 根据大数律有

$$a_k \xrightarrow{p} \alpha_k, \quad m_k \xrightarrow{p} \mu_k$$

从而我们可以使用 a_k, m_k 分别估计 α_k, μ_k , 进而得到 θ 的估计. 介绍如下: 假设总体 X 包含 k 个未知参数 $\theta = (\theta_1, \dots, \theta_k)$, 由方程组

$$\begin{cases} \alpha_1 = f_1(\theta_1, \dots, \theta_k) \\ \vdots \\ \alpha_k = f_k(\theta_1, \dots, \theta_k) \end{cases}$$

反解得到

$$\begin{cases} \theta_1 = g_1(\alpha_1, \dots, \alpha_k) \\ \vdots \\ \theta_k = g_k(\alpha_1, \dots, \alpha_k) \end{cases}$$

将其中的总体矩用相应的样本矩代替，则我们可以得到参数 $\theta_1, \dots, \theta_k$ 的一个估计：

$$\begin{cases} \hat{\theta}_1 = g_1(a_1, \dots, a_k) \\ \vdots \\ \hat{\theta}_k = g_k(a_1, \dots, a_k) \end{cases}$$

若要估计参数 $\theta_1, \dots, \theta_k$ 的某函数 $g(\theta_1, \dots, \theta_k)$ ，则用 $g(\hat{\theta}_1, \dots, \hat{\theta}_k)$ 去估计它。

这里我们用的都是原点矩 α_k ，当然也可以使用中心矩 μ_k ，或者两个都使用。在这种情况下，只需要把相应的总体矩换成样本矩。我们称这种估计方法为矩估计法，得到的估计量称为矩估计量。**矩估计方法应用的原则是：能用低阶矩处理的就不用高阶矩。**

矩估计法的优点是简单易行, 有些情况下不需要事先知道总体是什么分布. 缺点是, 当总体类型已知时, 没有充分利用分布提供的信息. 一般场合下, 矩估计量不具有唯一性.

投掷一枚硬币, 为了解正面出现的概率, 现独立重复的投掷 n 次, 用 X_1, \dots, X_n 表示投掷结果. 显然此时总体 X 的分布为 $B(1, p)$, p 为感兴趣的量. 而 X_1, \dots, X_n 为样本, 则求参数 p 的矩估计量。

↑Example

↓Example

解: 由于 $EX = p$, 而样本均值 \bar{X} 收敛到总体均值 EX , 因此 p 的一个矩估计量为 $\hat{p} = \bar{X}$.

为考察某种考试成绩分布情况, 使用正态分布 $N(a, \sigma^2)$ 来作为总体 X 的分布. 现在从中随机调查 n 个人, 即样本为 X_1, \dots, X_n . 试求参数 a, σ^2 的矩估计量。

↑Example

↓Example

6.1.2 最大似然估计方法

最大似然方法到目前为止应用最广的的点估计方法. 这种方法是基于如下的看法:

设样本 $X = (X_1, \dots, X_n)$ 有概率函数

$$f(x; \theta) = f(x; \theta_1, \dots, \theta_k)$$

Definition

这里参数 $\theta = (\theta_1, \dots, \theta_k) \in \Theta$, $x = (x_1, \dots, x_n)$ 为样本 X 的观察值. 当固定 x 时把 $f(x; \theta)$ 看成为 θ 的函数, 称为似然函数, 常记为 $L(x; \theta)$ 或 $L(\theta)$.

当固定参数 θ 时, $f(x; \theta)$ 可以看成是得到样本观察值 x 的可能性, 这样, 当把参数 θ 看成变动时, 也就得到“在不同的 θ 值下能观察到 x 的可能性大小, 即 $L(x; \theta)$ ”; 由于我们已经观察到了 x , 所以

使得能观察到 x 的可能性 $L(x; \theta)$ 最大的 θ 值, 看起来应该最像未知的 θ 。这个 θ 的值即称为 θ 最大似然估计值(看上去最有可能的)。我们先看一个例子:

从鱼池里随机捕捞 500 条鱼, 做好记号后重新放入鱼池中, 待充分混合后再捕捞 1000 条鱼, 结果发现其中有 72 条带有记号. 试问鱼池中可能有多少条鱼.

↑Example

↓Example

现给出最大似然估计的一般性定义:

设 $X = (X_1, \dots, X_n)$ 为从具有概率函数 $f_\theta(x)$ 的总体中抽取的样本, θ 为未知参数或者参数向量. $x = (x_1, \dots, x_n)$ 为样本的观察值. 若在给定 x 时, 值 $\hat{\theta} = \hat{\theta}(x)$ 满足下式

$$L(\hat{\theta}) = \max_{\theta \in \Theta} L(x; \theta)$$

Definition

则称 $\hat{\theta}$ 为参数 θ 的最大似然估计值, 而 $\hat{\theta}(X)$ 称为参数 θ 的最大似然估计量. 若待估参数为 θ 的函数 $g(\theta)$, 则 $g(\theta)$ 的最大似然估计量为 $g(\hat{\theta})$.

求最大似然估计值相当于求似然函数的最大值。在简单样本的情况下,

$$L(x; \theta) = \prod_{i=1}^n f_{\theta}(x_i)$$

而把似然函数的对数 $l(\theta) = \log L(\theta)$ 称为对数似然函数 (这是由于在一些情况下, 处理对数似然函数更方便)

当似然函数对变量 θ 单调时, 我们可以容易得到其最大值点. 反之当似然函数为非单调函数且对变量 θ 可微分时, 我们可以求其驻点: 令

$$\frac{dl(\theta)}{d\theta} = 0 \quad (\text{或者} \frac{dL(\theta)}{d\theta} = 0)$$

当 θ 为多维时, 比如 $\theta = (\theta_1, \dots, \theta_k)$ 时令

$$\frac{\partial l(\theta)}{\partial \theta_i} = 0 \quad (\text{或者} \frac{\partial L(\theta)}{\partial \theta_i} = 0) \quad i = 1, \dots, k$$

然后判断此驻点是否是最大值点。

设 X_1, \dots, X_n 为从总体 $X \sim N(a, \sigma^2)$ 中抽取的样本, 求参数 a, σ^2 的最大似然估计量。

↑Example

↓Example

解:

设总体 X 服从 $[a, b]$ 上的均匀分布, $a < b$, 求参数 a, b 的最大似然估计.

↑Example

↓Example

解:

设 X_1, \dots, X_n 为从具有如下形式密度的总体中抽取的样本:

↑Example

$$f(x; a, b) = \begin{cases} \frac{1}{b} \exp\{-\frac{x-a}{b}\} & , x > a \\ 0 & , x \leq a \end{cases}$$

求参数 a, b 的最大似然估计量.

↓Example

解:

解是最大值点。从而得到 a, b 的最大似然估计量:

$$\begin{cases} \hat{a} = X_{(1)} \\ \hat{b} = \frac{1}{n} \sum_{i=1}^n (X_i - X_{(1)}). \end{cases}$$

设总体 X_1, \dots, X_n 服从 0-1 分布 $B(1, p)$, $0 < p < 1$, 求参数 p 的最大似然估计.

↑Example

↓Example

解:

设总体 X_1, \dots, X_n 服从柯西分布 $f(x) = \frac{1}{\pi} \frac{1}{1+(x-\theta)^2}$, $x \in R, \theta \in R$, 求参数 θ 的最大似然估计.

↑Example

↓Example

解:

设 X_1, \dots, X_n 为从如下分布中抽取的简单样本, 求 θ 的最大似然估计.

↑Example

$$f(x) = \frac{1}{x!(2-x)!} [\theta^x (1-\theta)^{2-x} + \theta^{2-x} (1-\theta)^x], \quad x = 0, 1, 2; \quad \theta \in (0, \frac{1}{2})$$

↓Example

解:

再记 $n_i = \#\{X_1, \dots, X_n \text{ 中等于 } i \text{ 的个数}\}$, $i = 0, 1, 2$, 则得到似然函数为

$$L(\eta) = \left(\frac{1}{2}(1-\eta)\right)^{n_0} \eta^{n_1} \left(\frac{1}{2}(1-\eta)\right)^{n_2} = \left(\frac{1}{2}(1-\eta)\right)^{n-n_1} \eta^{n_1}$$

求解并注意 η 的上界即得到 η 的最大似然估计为

$$\hat{\eta} = \min\left\{\frac{n_1}{n}, \frac{1}{2}\right\}$$

再由 $\theta = \frac{1-\sqrt{1-2\eta}}{2}$ 得到 θ 的最大似然估计为

$$\hat{\theta} = \frac{1 - \sqrt{1 - 2\hat{\eta}}}{2}$$

6.1.3 点估计的优良准则

我们看到对同一个参数，有多个不同的估计量，因此，评选不同估计量的优劣性是需要考虑的。

1. 相合性

设总体分布依赖于参数 $\theta_1, \dots, \theta_k$, $g(\theta_1, \dots, \theta_k)$ 是待估参数函数。设 X_1, \dots, X_n 为自该总体中抽取的样本， $T(X_1, \dots, X_n)$ 为 $g(\theta_1, \dots, \theta_k)$ 的一个估计量，如果对任意的 $\epsilon > 0$ 和 $\theta_1, \dots, \theta_k$ 的一切可能值都有

$$\lim_{n \rightarrow \infty} P_{\theta_1, \dots, \theta_k} (|T(X_1, \dots, X_n) - g(\theta_1, \dots, \theta_k)| \geq \epsilon) = 0$$

我们则称 $T(X_1, \dots, X_n)$ 为 $g(\theta_1, \dots, \theta_k)$ 的一个 (弱)相合估计量 (Consistent Estimator)。

相合性是对一个估计量的最基本的要求，如果一个估计量没有相合性，那么无论样本大小多大，我们也不能把未知参数估计到任意预定的精度。这种估计量显然是不可取的。

矩估计量是满足相合性的，最大似然估计量在很一般的条件下也是满足相合性的。

2. 无偏性

设 $\hat{g}(X_1, \dots, X_n)$ 为待估参数函数 $g(\theta)$ 的一个估计量，若

$$E\hat{g}(X_1, \dots, X_n) = g(\theta)$$

则称 $\hat{g}(X_1, \dots, X_n)$ 为 $g(\theta)$ 的**无偏估计量 (Unbiased Estimator)**。无偏性的实际意义就是无系统误差。因此在有多个估计量可供选择时，我们优先考虑无偏估计量。

很多时候我们得到的估计量是有偏，例如正态总体的方差 σ^2 的最大似然估计量 $\hat{\sigma}^2 = \frac{1}{n} \sum_{i=1}^n (X_i - \bar{X})^2$ 是有偏的， $E\hat{\sigma}^2 = \frac{n-1}{n}\sigma^2$ 。若以 $\frac{n}{n-1}$ 乘以 $\hat{\sigma}^2$ ，所得到的估计量就是无偏的。这种方法称为修正。

若某一参数存在多个无偏估计时，如何选择使用哪个估计量？人们又在无偏性的基础上增加对方差的要求。

3. 有效性

设 $\hat{g}_1(X_1, \dots, X_n)$ 和 $\hat{g}_2(X_1, \dots, X_n)$ 为待估参数函数 $g(\theta)$ 的两个不同的无偏估计量, 若对任意的 $\theta \in \Theta$, 有

$$\text{Var}(\hat{g}_1(X_1, \dots, X_n)) \leq \text{Var}(\hat{g}_2(X_1, \dots, X_n))$$

而且至少对某个 $\theta_0 \in \Theta$ 使得严格不等式成立。则称 \hat{g}_1 较 \hat{g}_2 有效。

设 X_1, \dots, X_n 为从如下分布中抽取的简单样本，试证明样本方差为总体方差的无偏估计.

↑Example

↓Example

证:

设总体 X 服从 $(0, \theta)$ 上的均匀分布, $0 < \theta$, 求参数 θ 的最大似然估计是否为无偏估计.

↑Example

↓Example

解:

设 X_1, \dots, X_n 来自均值为 μ , 方差为 σ^2 的总体分布的简单样本, $\omega_1, \dots, \omega_n$ 为已知的非负权值, 且满足 $\sum \omega_i = 1$, 试比较 μ 的两个估计估计 \bar{X} 和 $\sum_{i=1}^n \omega_i X_i$.

↑Example

↓Example

解:

4. 渐近正态性

估计量是样本 X_1, \dots, X_n 的函数，其确切的分布一般不是容易得到。但是，许多形式很复杂的统计量 (未必是和)，当 n 很大时，其分布都渐近于正态分布，这个性质称为统计量的“渐近正态性”。

无偏性和有效性都是对固定的样本大小 n 而言的，这种性质称为估计量的“小样本性质”，而相合性和渐近正态性都是考虑在样本大小趋于无穷时的性质，这种性质称为“大样本性质”。

设从总体

↑Example

X	0	1	2	3
P	$\theta/2$	θ	$3\theta/2$	$1 - 3\theta$

抽取的一个简单样本 X_1, \dots, X_{10} 的观察值为 $(0, 3, 1, 1, 0, 2, 0, 0, 3, 0)$,

(1) 求 θ 的矩估计量 $\hat{\theta}_M$ 和最大似然估计量 $\hat{\theta}_L$, 并求出估计值。

(2) 上述估计量是否为无偏的? 若不是, 请作修正。

(3) 比较修正后的两个估计量, 指出那个更有效。

↓Example

由有效性的定义, 我们自然会问在一切可能的无偏估计里, 能否找到具有最小方差的无偏估计量? 如果存在这样的估计量, 我们称其为最小方差无偏估计量, 详细地可以参考课本。