

第六章 参数估计

§ 6.1 点估计

§ 6.2 点估计的评价标准

§ 6.3 最小方差无偏估计

§ 6.4 贝叶斯估计

§ 6.5 区间估计



§ 6.1 点估计

- 一 点估计概念
- 二 矩估计法
- 三 极大似然估计法



实例 制衣厂为了合理的确定服装各种尺码的生产比例，需要调查人们身长的分布。现从男性成人人群中随机选取100人,得到他们的身长数据为:....

若已知 X 服从正态分布 $N(\mu, \sigma^2)$,试估计参数的 μ, σ^2 值

已知“总体”的分布类型,对分布中的未知参数进行统计推断.



一、点估计问题

设总体 X 的分布函数形式已知, 但它的一个或多个参数为未知, 借助于总体 X 的一个样本来估计总体未知参数的值的问题称为点估计问题.

总体参数, 指总体分布 $F(x; \theta)$ 的数学表达式中所含的参数 θ

例如, 正态分布 $N(\mu, \sigma^2)$ 的参数为 μ, σ^2 ; 泊松分布 $P(\lambda)$ 的参数为 λ 等等。



二 参数的点估计

定义1.1 设 X_1, X_2, \dots, X_n 是来自总体 X 的样本, θ 为总体分布 $F(x; \theta)$ 中的未知参数, 构造一个统计量 $T = T(X_1, X_2, \dots, X_n)$ 作为 θ 的估计, 则称 $T = T(X_1, X_2, \dots, X_n)$ 为 θ 的估计量; 若样本 X_1, X_2, \dots, X_n 的一个观察值为 x_1, x_2, \dots, x_n , 则称 $T = T(x_1, x_2, \dots, x_n)$ 为

θ 的估计值, 统称为参数 θ 的点估计, 记作 $\hat{\theta}$.



即 $\hat{\theta} = \hat{\theta}(X_1, X_2, \dots, X_n)$ 为 θ 的点估计量
 $\hat{\theta} = \hat{\theta}(x_1, x_2, \dots, x_n)$ 为 θ 的点估计值

注1. 点估计实际上是指用统计量的值去估计未知参数的值, 又指用来估计未知参数的统计量, 例如, 用样本均值估计总体数学期望, 用样本方差估计总体方差, 用频率估计概率。



注2 若总体分布 $F(x; \theta_1, \theta_2, \dots, \theta_r)$ 中含有 r 个不同的未知参数, 则须由样本 X_1, X_2, \dots, X_n 建立 r 个统计量 $T_i(X_1, X_2, \dots, X_n), (1 \leq i \leq r)$ 来作为相应参数 $\theta_i (1 \leq i \leq r)$ 的点估计。

例如正总体 $N(u, \sigma^2)$ 有两个未知参数 μ 及 σ^2 而 $E(X) = \mu, D(X) = \sigma^2$, 可分别用

样本均值 $T_1 = \bar{X}$ 与样本方差 $T_2 = S^2$ 加以估计。



矩有原点矩与中心矩:

原点矩:

指随机变量 ξ k 次幂的数学期望 $E\xi^k$

$E\xi$ 1阶原点矩 $E\xi^2$ 2阶原点矩

设 X 是总体, X_1, X_2, \dots, X_n 是 X 的一个样本.

$E(X^k)$ 称为总体 X 的 k 阶原点矩;


$$\frac{1}{n} \sum_{i=1}^n X_i^k$$

称为样本的 k 阶原点矩.

中心矩: $E(\xi - \mu)^k$

是指随机变量 ξ 的离差 $\xi - \mu$ 的 k 次幂的数学期望

$E(\xi - \mu)^2$ 2阶中心矩.

设 X 是总体, X_1, X_2, \dots, X_n 是 X 的一个样本.

$E(X - \mu)^k$ 称为总体 X 的 k 阶中心矩;

$\frac{1}{n} \sum_{i=1}^n (X_i - \bar{X})^k$ 称为样本的 k 阶中心矩;



二 矩估计法

定义1.2 设总体 X 的分布函数 $F(x; \theta_1, \theta_2, \dots, \theta_r)$ 中有 r 个未知参数 $\theta_1, \theta_2, \dots, \theta_r$, 假定总体 X 的 k 阶原点矩 $E(X^k)$ ($1 \leq k \leq r$) 存在, 一般来说, $E(X^k)$ 依赖于未知参数 $\theta_1, \dots, \theta_r$, 记作

$$E(X^k) = V_k(\theta_1, \theta_2, \dots, \theta_r) \quad (1 \leq k \leq r) \quad (1.1)$$

令它等于 k 阶样本原点矩

$$\overline{X^k} = \frac{1}{n} \sum_{i=1}^n X_i^k \quad (1.2)$$



即令


$$E(X^k) = V_k(\theta_1, \theta_2, \dots, \theta_r) = \frac{1}{n} \sum_{i=1}^n X_i^k \quad (1 \leq k \leq r)$$

由上面的方程组解出 r 个值

$$\hat{\theta}_i = \hat{\theta}_i(X_1, X_2, \dots, X_n) \quad (1 \leq k \leq r)$$

分别取 $\hat{\theta}_i$ 作为 θ_i 的估计量, 这种求估计量的方法称之为矩估计法, 由此得到的估计量称为矩估计量。若有一样本值 x_1, x_2, \dots, x_n , 则称

$$\hat{\theta}_i = \hat{\theta}_i(x_1, x_2, \dots, x_n) \text{ 为矩估计值。}$$



矩估计法:

其基本思想是替换原理, 用样本 k 阶矩作为总体 k 阶矩的估计量, 建立含有待估参数的方程或方程组, 从而解出待估参数

其特点是不需要假定总体分布有明确的分布类型。



矩估计法的具体步骤:

(1). 求出 $\mu_k = E(X^k) = V_k(\theta_1, \theta_2, \dots, \theta_r) \quad k = 1, 2, \dots, r$

(2). 令 $\mu_k = \overline{X^k}$, 其中 $\overline{X^k} = \frac{1}{n} \sum_{i=1}^n X_i^k; k = 1, 2, \dots, r$

这是一个包含 r 个未知参数 $\theta_1, \theta_2, \dots, \theta_r$ 的方程组.

(3). 解出其中 $\theta_1, \theta_2, \dots, \theta_r$, 用 $\hat{\theta}_1, \hat{\theta}_2, \dots, \hat{\theta}_r$ 表示.

(4). 用方程组的解 $\hat{\theta}_1, \hat{\theta}_2, \dots, \hat{\theta}_r$ 分别作为 $\theta_1, \theta_2, \dots, \theta_r$ 的估计量, 这个估计量称为矩估计量.

矩估计量的观察值称为矩估计值.



例 设总体 X 在 $[0, \theta]$ 上服从均匀分布, 其中 θ ($\theta > 0$) 未知, (X_1, X_2, \dots, X_n) 是来自总体 X 的样本, 求 θ 的估计量.

解 因为 $\mu_1 = E(X) = \frac{\theta}{2},$

根据矩估计法, 令 $\frac{\hat{\theta}}{2} = \bar{X},$

所以 $\hat{\theta} = 2\bar{X}$ 为所求 θ 的估计量.



例2.2 设总体 X 在 $[a, b]$ 上服从均匀分布, 其中 a , b 未知, (X_1, X_2, \dots, X_n) 是来自总体 X 的样本, 求 a , b 的估计量.

解 $\mu_1 = E(X) = \frac{a+b}{2},$

$$\mu_2 = E(X^2) = D(X) + [E(X)]^2 = \frac{(a-b)^2}{12} + \frac{(a+b)^2}{4},$$

$$\text{令 } \frac{a+b}{2} = \bar{X} = \frac{1}{n} \sum_{i=1}^n X_i,$$

$$\frac{(a-b)^2}{12} + \frac{(a+b)^2}{4} = \overline{X^2} = \frac{1}{n} \sum_{i=1}^n X_i^2,$$



$$\text{即} \begin{cases} a + b = 2\bar{X}, \\ b - a = \sqrt{12(\overline{X^2} - \bar{X}^2)}. \end{cases}$$

解方程组得到 a, b 的矩估计量分别为

$$\hat{a} = \bar{X} - \sqrt{3(\overline{X^2} - \bar{X}^2)} = \bar{X} - \sqrt{\frac{3}{n} \sum_{i=1}^n (X_i - \bar{X})^2},$$

$$\hat{b} = \bar{X} + \sqrt{3(\overline{X^2} - \bar{X}^2)} = \bar{X} + \sqrt{\frac{3}{n} \sum_{i=1}^n (X_i - \bar{X})^2}.$$



例2.3 设总体 X 的均值 μ 和方差 σ^2 都存在, 且有 $\sigma^2 > 0$, 但 μ 和 σ^2 均为未知, 又设 X_1, X_2, \dots, X_n 是一个样本, 求 μ 和 σ^2 的矩估计量.

解

$$\mu_1 = E(X) = \mu,$$

$$\mu_2 = E(X^2) = D(X) + [E(X)]^2 = \sigma^2 + \mu^2,$$

$$\text{令} \begin{cases} \mu = \bar{X}, \\ \sigma^2 + \mu^2 = \overline{X^2}. \end{cases}$$

解方程组得到矩估计量分别为 $\hat{\mu} = \bar{X},$

$$\hat{\sigma}^2 = \overline{X^2} - \bar{X}^2 = \frac{1}{n} \sum_{i=1}^n X_i^2 - \bar{X}^2 = \frac{1}{n} \sum_{i=1}^n (X_i - \bar{X})^2 =: S_n^2$$

(二阶中心距)



上例表明：总体均值与方差的矩估计量的表达式不因不同的总体分布而异。

例 $X \sim N(\mu, \sigma^2)$, μ, σ^2 未知, 即得 μ, σ^2 的矩估计量

$$\hat{\mu} = \bar{X}, \quad \hat{\sigma}^2 = \frac{1}{n} \sum_{i=1}^n (X_i - \bar{X})^2.$$

一般地,

用样本均值 $\bar{X} = \frac{1}{n} \sum_{i=1}^n X_i$ 作为总体 X 的均值的矩估计 ,

用样本二阶中心矩 $S_n^2 = \frac{1}{n} \sum_{i=1}^n (X_i - \bar{X})^2$ 作为总体

X 的方差的矩估计 .



注. 1 定义中选用的是原点矩，也可以用中心矩，只要给定总体矩，采用相应的样本矩就可以。

2 若 $\hat{\theta}$ 为 θ 的矩估计量， $g(\theta)$ 为 θ 的连续函数，亦称 $g(\hat{\theta})$ 为 $g(\theta)$ 的矩估计量。

例如， S_n^2 为总体方差 σ^2 的矩估计量，则

$S_n = \sqrt{S_n^2}$ 为标准差 σ 的矩估计量。

3 矩估计的关键是计算总体矩，因此使用矩估计法其前提是总体矩必须存在。



例2.4 设 X_1, X_2, \dots, X_n 是来自总体 X 的样本, 当 X 的分布为

(1) 正态分布 $N(\mu, \sigma^2)$

(2) 指数分布 $E(\lambda)$

(3) 均匀分布 $U(a, b)$

(4) 二项分布 $B(n, p)$

(5) 泊松分布 $P(\lambda)$

试求其中未知参数的矩估计。

解:(1) 因为 $X \sim N(\mu, \sigma^2)$, $E(X) = \mu$, $D(X) = \sigma^2$

故有 $\hat{\mu} = \bar{X}$, $\hat{\sigma}^2 = S_n^2$

(2) $X \sim E(\lambda)$, $E(X) = \frac{1}{\lambda}$

故 $\frac{1}{\lambda} = \bar{X}$, 即 $\hat{\lambda} = \frac{1}{\bar{X}}$



$$(3) \quad X \sim U(a, b), \quad E(X) = \frac{a+b}{2}, \quad D(X) = \frac{(b-a)^2}{12}$$

$$\text{故有} \begin{cases} \frac{a+b}{2} = \overline{X} \\ \frac{(b-a)^2}{12} = S_n^2 \end{cases} \quad \text{即} \begin{cases} a+b = 2\overline{X} \\ b-a = 2\sqrt{3}S_n \end{cases}$$

$$\text{解出得:} \quad \hat{a} = \overline{X} - \sqrt{3}S_n \quad \hat{b} = \overline{X} + \sqrt{3}S_n$$



(4) $X \sim B(n, p), E(X) = np, D(X) = np(1-p)$

故有
$$\begin{cases} np = \overline{X} \\ np(1-p) = S_n^2 \end{cases} \quad \text{即} \begin{cases} \hat{p} = 1 - \frac{S_n^2}{\overline{X}} \\ \hat{n} = \frac{\overline{X}}{\hat{p}} = \frac{\overline{X}^2}{\overline{X} - S_n^2} \end{cases}$$

(5) $X \sim P(\lambda), E(X) = D(X) = \lambda$

故 $\hat{\lambda} = \overline{X}$ 或 $\hat{\lambda} = S_n^2$

注：由此例可知，矩估计量不唯一。



例2.5 设总体 X 的概率密度为

$$f(x; \theta) = \begin{cases} (\theta + 1)x^\theta & 0 < x < 1 \\ 0 & \text{其它} \end{cases} \quad (\theta > -1)$$

X_1, X_2, \dots, X_n 是来自总体 X 的样本。0.1, 0.2, 0.9, 0.8, 0.7, 0.7为一个样本观察值，试求 θ 的矩估计值。

解： $E(X) = \int_{-\infty}^{+\infty} xf(x; \theta)dx = \int_0^1 x(\theta + 1)x^\theta dx = (\theta + 1) \int_0^1 x^{\theta+1} dx$

$$= (\theta + 1) \frac{1}{\theta + 2} x^{\theta+2} \Big|_0^1 = \frac{\theta + 1}{\theta + 2}$$

令 $\frac{\theta + 1}{\theta + 2} = \bar{X}$ 解之得 θ 的矩估计 $\hat{\theta} = \frac{2\bar{X} - 1}{1 - \bar{X}}$

由样本值 0.1, 0.2, 0.9, 0.8, 0.7, 0.7 计算得 $\bar{x} = 0.5667$

故 θ 的矩估计值为 $\hat{\theta} = \frac{2\bar{x} - 1}{1 - \bar{x}} = 0.3079$



例2.6 设总体X的概率密度为

$$f(x, \theta) = \frac{1}{2\theta} e^{-\frac{|x|}{\theta}} \quad -\infty < x < +\infty, \theta > 0$$

试求 θ 的矩估计量 $\hat{\theta}$ 。

法1 解：虽然 $f(x; \theta)$ 中仅含一个未知参数 θ ，但因

$$E(X) = \int_{-\infty}^{+\infty} x \frac{1}{2\theta} e^{-\frac{|x|}{\theta}} dx = 0$$

不含 θ ，不能由此解出，故需继续求出总体二阶原点矩：

$$\begin{aligned} E(X^2) &= \int_{-\infty}^{+\infty} x^2 \frac{1}{2\theta} e^{-\frac{|x|}{\theta}} dx = \int_0^{+\infty} x^2 \frac{1}{\theta} e^{-\frac{x}{\theta}} dx \\ &= \theta^2 + \theta^2 = 2\theta^2 \end{aligned}$$

故令 $2\theta^2 = \overline{X^2} = \frac{1}{n} \sum_{i=1}^n X_i^2$ ，得 θ 的矩估计量 $\hat{\theta} = \sqrt{\frac{1}{2n} \sum_{i=1}^n X_i^2}$



法2 考虑 $|X|$ 的数学期望,

$$E(|X|) = \int_{-\infty}^{+\infty} |x| \frac{1}{2\theta} e^{-\frac{|x|}{\theta}} dx = \int_0^{+\infty} x \frac{1}{\theta} e^{-\frac{x}{\theta}} dx = \theta$$

可得出 θ 的另一矩估计量 $\hat{\theta} = \frac{1}{n} \sum_{i=1}^n |X_i|$

对同一参数, 其矩估计量不唯一。



2. 最大似然估计法

(1) 设总体 X 属离散型

似然函数的定义

设分布律 $P\{X = k\} = p(x; \theta)$, θ 为待估参数, $\theta \in \Theta$,

(其中 Θ 是 θ 可能的取值范围)

X_1, X_2, \dots, X_n 是来自总体 X 的样本,

则 X_1, X_2, \dots, X_n 的联合分布律为
$$\prod_{i=1}^n p(x_i; \theta).$$



又设 x_1, x_2, \dots, x_n 为相应于样本 X_1, X_2, \dots, X_n 的一个样本值 .

则样本 X_1, X_2, \dots, X_n 取到观察值 x_1, x_2, \dots, x_n 的概率 ,
即事件 $X_1 = x_1, X_2 = x_2, \dots, X_n = x_n$ 发生的概率为

$$L(\theta) = L(x_1, x_2, \dots, x_n; \theta) = \prod_{i=1}^n p(x_i; \theta), \quad \theta \in \Theta,$$

$L(\theta)$ 称为样本似然函数



最大似然估计法

得到样本值 x_1, x_2, \dots, x_n 时, 选取使似然函数 $L(\theta)$

取得最大值的 $\hat{\theta}$ 作为未知参数 θ 的估计值 ,

即 $L(x_1, x_2, \dots, x_n; \hat{\theta}) = \max_{\theta \in \Theta} L(x_1, x_2, \dots, x_n; \theta)$.



(2) 设总体 X 属连续型

似然函数的定义


设概率密度为 $f(x; \theta)$, θ 为待估参数, $\theta \in \Theta$,

(其中 Θ 是 θ 可能的取值范围)

X_1, X_2, \dots, X_n 是来自总体 X 的样本,

则 X_1, X_2, \dots, X_n 的联合密度为 $\prod_{i=1}^n f(x_i; \theta)$.

又设 x_1, x_2, \dots, x_n 为相应于样本 X_1, X_2, \dots, X_n 的一个样本值.



则随机点 (X_1, X_2, \dots, X_n) 落在点 (x_1, x_2, \dots, x_n) 的邻域 (边长分别为 dx_1, dx_2, \dots, dx_n 的 n 维立方体) 内的概率近似地为

$$\prod_{i=1}^n f(x_i; \theta) dx_i,$$


$$L(\theta) = L(x_1, x_2, \dots, x_n; \theta) = \prod_{i=1}^n f(x_i; \theta),$$

$L(\theta)$ 称为样本的似然函数 .

若 $L(x_1, x_2, \dots, x_n; \hat{\theta}) = \max_{\theta \in \Theta} L(x_1, x_2, \dots, x_n; \theta).$

$\hat{\theta}(x_1, x_2, \dots, x_n)$ 参数 θ 的最大似然估计值,

$\hat{\theta}(X_1, X_2, \dots, X_n)$ 参数 θ 的最大似然估计量



1 极大似然估计概念

定义1.3 设总体 X 的分布函数 $F(x; \theta)$ 的形式已知, θ 为未知参数, Θ 为 θ 的可能取值范围, x_1, x_2, \dots, x_n 为 X 的一个样本值,

若存在 $\hat{\theta} = \hat{\theta}(x_1, x_2, \dots, x_n)$, 使得似然函数

$$L(x_1, x_2, \dots, x_n; \hat{\theta}) = \max_{\theta \in \Theta} L(x_1, x_2, \dots, x_n; \theta)$$

则称 $\hat{\theta} = \hat{\theta}(x_1, x_2, \dots, x_n)$ 为 θ 的极大似然估计值,



$\hat{\theta} = \hat{\theta}(X_1, X_2, \dots, X_n)$ 为 θ 的极大似然估计量 ,

统称为 θ 的极大似然估计。 .

注1 : 似然函数实际上是样本的密度函数或概率分布:

$$L(x_1, x_2, \dots, x_n; \theta) = \prod_{i=1}^n f(x_i; \theta) \quad (X \text{ 为连续型}) \quad (1.4)$$

$$L(x_1, x_2, \dots, x_n; \theta) = \prod_{i=1}^n P\{X_i = x_i; \theta\} \quad (X \text{ 为离散型}) \quad (1.5)$$



注2 若总体分布中含有两个 以上的未知参数 $\theta_1, \theta_2, \dots, \theta_r$ 时, 则 θ_i 的极大似然估计 $\hat{\theta}_i$ 满足

$$L(x_1, \dots, x_n; \hat{\theta}_1, \dots, \hat{\theta}_r) = \max L(x_1, \dots, x_n; \theta_1, \dots, \theta_r)$$



2 求最大似然估计量的步骤:

(一) 写出似然函数

$$L(\theta) = L(x_1, x_2, \dots, x_n; \theta) = \prod_{i=1}^n p(x_i; \theta)$$

或
$$L(\theta) = L(x_1, x_2, \dots, x_n; \theta) = \prod_{i=1}^n f(x_i; \theta);$$

(二) 取对数

$$\ln L(\theta) = \sum_{i=1}^n \ln p(x_i; \theta) \quad \text{或} \quad \ln L(\theta) = \sum_{i=1}^n \ln f(x_i; \theta);$$



(三) 对 θ 求导 $\frac{d \ln L(\theta)}{d \theta}$, 并令 $\frac{d \ln L(\theta)}{d \theta} = 0$, **对数似然方程**

解方程即得未知参数 θ 的最大似然估计值 $\hat{\theta}$.

最大似然估计法也适用于分布中含有多个未知参数的情况. 此时只需令

$$\frac{\partial}{\partial \theta_i} \ln L = 0, \quad i = 1, 2, \dots, k. \quad \text{对数似然方程组}$$

解出由 k 个方程组成的方程组, 即可得各未知参数 θ_i ($i = 1, 2, \dots, k$) 的最大似然估计值 $\hat{\theta}_i$.



例2.6 设 $X \sim B(1, p)$, X_1, X_2, \dots, X_n 是来自 X 的一个样本, 求 p 的最大似然估计量 .

解 设 x_1, x_2, \dots, x_n 为相应于样本 X_1, X_2, \dots, X_n 的一个样本值 ,

X 的分布律为 $P\{X = x\} = p^x (1 - p)^{1-x}, x = 0, 1,$

似然函数
$$L(p) = \prod_{i=1}^n p^{x_i} (1 - p)^{1-x_i}$$
$$= p^{\sum_{i=1}^n x_i} (1 - p)^{n - \sum_{i=1}^n x_i},$$



$$\ln L(p) = \left(\sum_{i=1}^n x_i \right) \ln p + \left(n - \sum_{i=1}^n x_i \right) \ln(1 - p),$$

$$\text{令 } \frac{d}{dp} \ln L(p) = \frac{\sum_{i=1}^n x_i}{p} - \frac{n - \sum_{i=1}^n x_i}{1 - p} = 0,$$

解得 p 的最大似然估计值 $p = \frac{1}{n} \sum_{i=1}^n x_i = \bar{x}.$

p 的最大似然估计量为 $\hat{p} = \frac{1}{n} \sum_{i=1}^n X_i = \bar{X}.$

这一估计量与矩估计量是相同的。



例2.7 设 X 服从参数为 λ ($\lambda > 0$) 的泊松分布 ,
 X_1, X_2, \dots, X_n 是来自 X 的一个样本 , 求 λ 的最大似然估计量 .

解 因为 X 的分布律为

$$P\{X = x\} = \frac{\lambda^x}{x!} e^{-\lambda}, \quad (x = 0, 1, 2, \dots, n)$$

所以 λ 的似然函数为

$$L(\lambda) = \prod_{i=1}^n \left(\frac{\lambda^{x_i}}{x_i!} e^{-\lambda} \right) = e^{-n\lambda} \frac{\lambda^{\sum_{i=1}^n x_i}}{\prod_{i=1}^n (x_i!)},$$



$$\ln L(\lambda) = -n\lambda + \left(\sum_{i=1}^n x_i \right) \ln \lambda - \sum_{i=1}^n (x_i!),$$

$$\text{令 } \frac{d}{d\lambda} \ln L(\lambda) = -n + \frac{\sum_{i=1}^n x_i}{\lambda} = 0,$$

解得 λ 的最大似然估计值 $\lambda = \frac{1}{n} \sum_{i=1}^n x_i = \bar{x},$

λ 的最大似然估计量为 $\hat{\lambda} = \frac{1}{n} \sum_{i=1}^n X_i = \bar{X}.$

这一估计量与矩估计量是相同的。



例2.8 设总体 $X \sim N(\mu, \sigma^2)$, μ, σ^2 为未知参数, x_1, x_2, \dots, x_n 是来自 X 的一个样本值, 求 μ 和 σ^2 的最大似然估计量.

解 X 的概率密度为

$$f(x; \mu, \sigma^2) = \frac{1}{\sqrt{2\pi}\sigma} e^{-\frac{(x-\mu)^2}{2\sigma^2}},$$

X 的似然函数为

$$L(\mu, \sigma^2) = \prod_{i=1}^n \frac{1}{\sqrt{2\pi}\sigma} e^{-\frac{(x_i-\mu)^2}{2\sigma^2}},$$



$$\ln L(\mu, \sigma^2) = -\frac{n}{2} \ln(2\pi) - \frac{n}{2} \ln \sigma^2 - \frac{1}{2\sigma^2} \sum_{i=1}^n (x_i - \mu)^2 ,$$

$$\text{令} \begin{cases} \frac{\partial}{\partial \mu} \ln L(\mu, \sigma^2) = 0, \\ \frac{\partial}{\partial \sigma^2} \ln L(\mu, \sigma^2) = 0, \end{cases}$$

$$\begin{cases} \frac{1}{\sigma^2} \left[\sum_{i=1}^n x_i - n\mu \right] = 0 , \\ -\frac{n}{2\sigma^2} + \frac{1}{2(\sigma^2)^2} \sum_{i=1}^n (x_i - \mu)^2 = 0 , \end{cases}$$



由 $\frac{1}{\sigma^2} \left[\sum_{i=1}^n x_i - n\mu \right] = 0$ 解得 $\hat{\mu} = \frac{1}{n} \sum_{i=1}^n x_i = \bar{x},$

由 $-\frac{n}{2\sigma^2} + \frac{1}{2(\sigma^2)^2} \sum_{i=1}^n (x_i - \mu)^2 = 0$ 解得

$$\hat{\sigma}^2 = \frac{1}{n} \sum_{i=1}^n (x_i - \bar{x})^2,$$

故 μ 和 σ^2 的最大似然估计量分别为

$\hat{\mu} = \bar{X}, \quad \hat{\sigma}^2 = \frac{1}{n} \sum_{i=1}^n (X_i - \bar{X})^2.$ 它们与相应的矩估计量相同.



例2.9 设总体 X 的概率密度为

$$f(x) = \begin{cases} (\theta + 1)x^\theta & 0 < x < 1 \\ 0 & \text{其它} \end{cases} \quad \theta > -1$$

0.1, 0.2, 0.9, 0.8, 0.7, 0.7 为一个样本观察值,
试求 θ 的极大似然估计。



$$\text{解 : i) } L(x_1, x_2, \dots, x_n; \theta) = \prod_{i=1}^n f(x_i; \theta) = \prod_{i=1}^n (\theta + 1)x_i^\theta = (\theta + 1)^n \left(\prod_{i=1}^n x_i \right)^\theta$$

$$0 \leq x_i \leq 1$$

$$\text{ii) } \ln L(x_1, x_2, \dots, x_n; \theta) = n \ln(\theta + 1) + \theta \sum_{i=1}^n \ln x_i$$

$$\text{iii) 令 : } \frac{d}{d\theta} [\ln L(x_1, x_2, \dots, x_n; \theta)] = \frac{n}{\theta + 1} + \sum_{i=1}^n \ln x_i = 0$$

$$\text{iv) 解之得: } \hat{\theta} = \frac{-n}{\sum_{i=1}^n \ln x_i} - 1 \quad \text{为 } \theta \text{ 的极大似然估计值。}$$

$$\text{而 } \hat{\theta} = \frac{-n}{\sum_{i=1}^n \ln X_i} - 1 \text{ 为 } \theta \text{ 的极大似然估计量。}$$

$$\text{又由样本值计算得 } \sum_{i=1}^n \ln x_i = -4.9539 \quad \text{故得 } \hat{\theta} = \frac{-6}{-4.9539} - 1 = 0.2112$$



例6.1.6 设一个试验有三种可能结果，其发

生概率 $p_1 = \theta^2$, $p_2 = 2\theta(1 - \theta)$, $p_3 = (1 - \theta)^2$

现做了 n 次试验，观测到三种结果发生的次数分别为 n_1, n_2, n_3 ($n_1 + n_2 + n_3 = n$)，则似然函数为

$$\begin{aligned} L(\theta) &= (\theta^2)^{n_1} [2\theta(1 - \theta)]^{n_2} [(1 - \theta)^2]^{n_3} \\ &= 2^{n_2} \theta^{2n_1 + n_2} (1 - \theta)^{2n_3 + n_2} \end{aligned}$$

其对数似然函数为

$$\ln L(\theta) = (2n_1 + n_2) \ln \theta + (2n_3 + n_2) \ln(1 - \theta) + n_2 \ln 2$$



将之关于 θ 求导，并令其为0得到似然方程

$$\frac{2n_1 + n_2}{\theta} - \frac{2n_3 + n_2}{1 - \theta} = 0$$

解之，得

$$\hat{\theta} = \frac{2n_1 + n_2}{2(n_1 + n_2 + n_3)} = \frac{2n_1 + n_2}{2n}$$

由于

$$\frac{\partial^2 \ln L(\theta)}{\partial \theta^2} = -\frac{2n_1 + n_2}{\theta^2} - \frac{2n_3 + n_2}{(1 - \theta)^2} < 0$$

所以 $\hat{\theta}$ 是极大值点。



(2) 利用极大似然估计定义求估计法

i) 建立似然函数

$$L(x_1, x_2, \dots, x_n; \theta_1, \theta_2, \dots, \theta_r) = \prod_{i=1}^n f(x_i; \theta_1, \theta_2, \dots, \theta_r)$$

ii) 由 x_1, x_2, \dots, x_n 确定顺序统计值

$$x_{(1)} \leq x_{(2)} \leq \dots \leq x_{(n)}$$



iii) 利用顺序统计值的函数 作出 $\theta_1, \theta_2, \dots, \theta_r$ 的
相应估计 $\hat{\theta}_1, \hat{\theta}_2, \dots, \hat{\theta}_n$, 使其满足条件

$$\begin{aligned} L(x_1, \dots, x_n; \hat{\theta}_1, \dots, \hat{\theta}_n) \\ = \max_{(\theta_1, \dots, \theta_r) \in \Theta} L(x_1, \dots, x_n; \theta_1, \dots, \theta_r) \end{aligned}$$

则 $\hat{\theta}_i$ 即为 $\theta_i (1 \leq i \leq r)$ 的极大似然估计。



例2.10 设总体 X 在 $[a, b]$ 上服从均匀分布, 其中 a, b 未知, x_1, x_2, \dots, x_n 是来自总体 X 的一个样本值, 求 a, b 的最大似然估计量.

解 记 $x_{(1)} = \min(x_1, x_2, \dots, x_n),$

$$x_{(n)} = \max(x_1, x_2, \dots, x_n),$$

X 的概率密度为

$$f(x; a, b) = \begin{cases} \frac{1}{b-a}, & a \leq x \leq b, \\ 0, & \text{其他.} \end{cases}$$



因为 $a \leq x_1, x_2, \dots, x_n \leq b$ 等价于 $a \leq x_{(1)}, x_{(n)} \leq b$,

作为 a, b 的函数的似然函数为

$$L(a, b) = \begin{cases} \frac{1}{(b-a)^n}, & a \leq x_{(1)}, b \geq x_{(n)}, \\ 0, & \text{其他} \end{cases}$$

于是对于满足条件 $a \leq x_{(1)}, b \geq x_{(n)}$ 的任意 a, b 有

$$L(a, b) = \frac{1}{(b-a)^n} \leq \frac{1}{(x_{(n)} - x_{(1)})^n},$$



即似然函数 $L(a, b)$ 在 $a = x_{(1)}$, $b = x_{(n)}$ 时

取到最大值 $(x_{(n)} - x_{(1)})^{-n}$,

a, b 的最大似然估计值

$$\hat{a} = x_{(1)} = \min_{1 \leq i \leq n} x_i,$$

$$\hat{b} = x_{(n)} = \max_{1 \leq i \leq n} x_i,$$

a, b 的最大似然估计量

$$\hat{a} = \min_{1 \leq i \leq n} X_i,$$

$$\hat{b} = \max_{1 \leq i \leq n} X_i.$$



例2.11 设 X_1, X_2, \dots, X_n 是取自总体 X 的一个样本

$$X \sim f(x) = \begin{cases} \frac{1}{\theta} e^{-(x-\mu)/\theta}, & x \geq \mu \\ 0, & \text{其它} \end{cases} \quad \theta, \mu \text{ 为未知参数}$$

其中 $\theta > 0$, 求 θ, μ 的极大似然估计.

解: 似然函数为

$$L(x_1, x_2, \dots, x_n, \theta, \mu) = \begin{cases} \prod_{i=1}^n \frac{1}{\theta} e^{-(x_i - \mu)/\theta}, & x_i \geq \mu \\ 0, & \text{其它} \end{cases}$$

$i=1, 2, \dots, n$



用求导方法无法最终确定 θ, μ ,
用极大似然原则来求.

对 θ, μ 分别求偏导并令其为0,

$$\frac{\partial \ln L(\theta, \mu)}{\partial \theta} = -\frac{n}{\theta} + \frac{1}{\theta^2} \sum_{i=1}^n (x_i - \mu) = 0 \quad (1)$$

$$\frac{\partial \ln L(\theta, \mu)}{\partial \mu} = \frac{n}{\theta} > 0 \quad (2) \quad \theta = \frac{1}{n} \sum_{i=1}^n x_i - \mu$$

由于

$$L(\theta, \mu) = \begin{cases} \frac{1}{\theta^n} e^{-\frac{1}{\theta} \sum_{i=1}^n (x_i - \mu)} & , \quad x_i \geq \mu \\ 0, & \text{其它} \end{cases}$$

对 $\mu \leq \min x_i$, $L(\theta, \mu) > 0$, 且是 μ 的增函数
 μ 取其它值时, $L(\theta, \mu) = 0$.

故使 $L(\theta, \mu)$ 达到最大的 μ , 即 μ 的MLE,

是 $\hat{\mu} = \min_{1 \leq i \leq n} x_i$

于是

$$\hat{\theta} = \frac{1}{n} \sum_{i=1}^n x_i - \hat{\mu}$$



例1.11 设总体 X 的密度函数为

$$f(x; \theta) = \begin{cases} 1 & \theta - \frac{1}{2} \leq x \leq \theta + \frac{1}{2} \\ 0 & \text{其它} \end{cases} \quad -\infty < x < +\infty$$

试求未知参数 θ 的极大似然估计.

解：

$$i) L(x_1, x_2, \dots, x_n; \theta) = \prod_{i=1}^n f(x_i; \theta) = 1 \quad \theta - \frac{1}{2} \leq x \leq \theta + \frac{1}{2}$$

ii) x_1, x_2, \dots, x 的顺序统计值为： $x_{(1)} \leq x_{(2)} \leq \dots \leq x_{(n)}$




iii) $L(x_1, x_2, \dots, x_n; \theta)$ 与 θ 无关而要: $\theta - \frac{1}{2} \leq x_1, x_2, \dots, x_n \leq \theta + \frac{1}{2}$

故
$$\theta - \frac{1}{2} \leq x_{(1)} \leq x_{(2)} \leq \dots \leq x_{(n)} \leq \theta + \frac{1}{2}$$

故由极大似然估计定义, 应有

$$\hat{\theta} - \frac{1}{2} = x_{(1)} = \min_{1 \leq i \leq n} \{x_i\}, \quad \hat{\theta} + \frac{1}{2} = x_{(n)} = \max_{1 \leq i \leq n} \{x_i\}$$



极大似然估计的不变性

设 $\hat{\theta}$ 是 θ 的极大似然估计值, $u(\theta)$
($\theta \in \Theta$) 是 θ 的函数, 且有单值反函数

$$\theta = \theta(u), \quad u \in U$$

则 $\hat{u} = u(\hat{\theta})$ 是 $u(\theta)$ 的极大似然估计值.



如 在正态总体 $N(\mu, \sigma^2)$ 中, σ^2 的极大似然估计值为

$$\hat{\sigma}^2 = \frac{1}{n} \sum_{i=1}^n (x_i - \bar{x})^2$$

$\sigma = \sqrt{\sigma^2}$ 是 σ^2 的单值函数, 且具有单值反函数, 故 σ 的极大似然估计值为

$$\hat{\sigma} = \sqrt{\frac{1}{n} \sum_{i=1}^n (x_i - \bar{x})^2}$$

$\lg \sigma$ 的极大似然估计值为

$$\hat{\lg \sigma} = \lg \sqrt{\frac{1}{n} \sum_{i=1}^n (x_i - \bar{x})^2}$$



三、小结

两种求点估计的方法: $\left\{ \begin{array}{l} \text{矩估计法} \\ \text{最大似然估计法} \end{array} \right.$

在统计问题中往往先使用最大似然估计法,
在最大似然估计法使用不方便时, 再用矩估计法.

$$\text{似然函数 } L(\theta) = L(x_1, x_2, \dots, x_n; \theta) = \prod_{i=1}^n p(x_i; \theta)$$

$$\text{或 } L(\theta) = L(x_1, x_2, \dots, x_n; \theta) = \prod_{i=1}^n f(x_i; \theta);$$



§ 6.2 点估计的评价标准

6.2.1 相合性

我们知道，点估计是一个统计量，因此它是一个随机变量，在样本量一定的条件下，我们不可能要求它完全等同于参数的真实取值。但如果我们有足够的观测值，根据格里文科定理，随着样本量的不断增大，经验分布函数逼近真实分布函数，因此完全可以要求估计量随着样本量的不断增大而逼近参数真值，这就是相合性，严格定义如下。



定义6.2.1 设 $\theta \in \Theta$ 为未知参数, $\hat{\theta}_n = \hat{\theta}_n(X_1, \dots, X_n)$ 是 θ 的一个估计量, n 是样本容量, 若对任何一个 $\varepsilon > 0$, 有

$$(6.2.1) \quad \lim_{n \rightarrow \infty} P(|\hat{\theta}_n - \theta| > \varepsilon) = 0$$

则称 $\hat{\theta}_n$ 为 θ 参数的相合估计。



相合性被认为是对估计的一个最基本要求，如果一个估计量，在样本量不断增大时，它都不能把被估参数估计到任意指定的精度，那么这个估计是很值得怀疑的。通常，不满足相合性要求的估计一般不予考虑。证明估计的相合性一般可应用大数定律或直接由定义来证。



若把依赖于样本量 n 的估计量 $\hat{\theta}_n$ 看作一个随机变量序列, 相合性就是 $\hat{\theta}_n$ 依概率收敛于 θ , 所以证明估计的相合性可应用依概率收敛的性质及各种大数定律。



在判断估计的相合性时下述两个定理是很有用的。

定理6.2.1 设 $\hat{\theta}_n = \hat{\theta}_n(x_1, \dots, x_n)$ 是 θ 的一个估计量, 若

$$\lim_{n \rightarrow \infty} E(\hat{\theta}_n) = \theta, \quad \lim_{n \rightarrow \infty} Var(\hat{\theta}_n) = 0$$

则 $\hat{\theta}_n$ 是 θ 的相合估计,

定理6.2.2 若 $\hat{\theta}_{n1}, \dots, \hat{\theta}_{nk}$ 分别是 $\theta_1, \dots, \theta_k$ 的相合估计, $\eta = g(\theta_1, \dots, \theta_k)$ 是 $\theta_1, \dots, \theta_k$ 的连续函数, 则 $\hat{\eta}_n = g(\hat{\theta}_{n1}, \dots, \hat{\theta}_{nk})$ 是 η 的相合估计。



例6.2.2 设 X_1, X_2, \dots, X_n 是来自均匀总体 $U(0, \theta)$ 的样本, 证明 θ 的极大似然估计是相合估计。

证明: 在例6.1.7中我们已经给出 θ 的极大似然估计是 $X_{(n)}$ 。由次序统计量的分布, 我们知道 $X_{(n)}$ 的分布密度函数为 $p(y) = ny^{n-1} / \theta^n, y < \theta$, 故有

$$E \hat{\theta} = \int_0^{\theta} ny^n dy / \theta^n = \frac{n}{n+1} \theta \rightarrow \theta$$

$$E \hat{\theta}^2 = \int_0^{\theta} ny^{n+1} dy / \theta^n = \frac{n}{n+2} \theta^2$$

$$\text{Var}(\hat{\theta}) = \frac{n}{n+2} \theta^2 - \left(\frac{n}{n+1} \theta \right)^2 = \frac{n}{(n+1)^2 (n+2)} \theta^2 \rightarrow 0,$$

由定理6.2.1可知, $x_{(n)}$ 是 θ 的相合估计。



由大数定律及定理6.2.2，我们可以看到：
矩估计一般都具有相合性。比如：

- 样本均值是总体均值的相合估计；
- 样本标准差是总体标准差的相合估计；
- 样本变异系数是总体变异系数的相合估计。



例8 试证：样本均值 \bar{X} 是总体均值 μ 的相合估计

量，样本方差 $S^2 = \frac{1}{n-1} \sum_{i=1}^n (X_i - \bar{X})^2$ 及样本的二阶

中心矩 $B_2 = \frac{1}{n} \sum_{i=1}^n (X_i - \bar{X})^2$ 都是总体方差 σ^2 的相合

估计量。

证明 由大数定律知，

$$\forall \varepsilon > 0, \text{ 有 } \lim_{n \rightarrow \infty} P \left\{ \left| \frac{1}{n} \sum_{i=1}^n X_i - \mu \right| < \varepsilon \right\} = 1,$$

所以 $\bar{X} = \frac{1}{n} \sum_{i=1}^n X_i$ 是 μ 的相合估计量。



$$\begin{aligned} \text{又 } B_2 &= \frac{1}{n} \sum_{i=1}^n (X_i - \bar{X})^2 = \frac{1}{n} \sum_{i=1}^n (X_i^2 - 2X_i\bar{X} + \bar{X}^2) \\ &= \frac{1}{n} \sum_{i=1}^n X_i^2 - \bar{X}^2 = A_2 - \bar{X}^2, \\ &\quad (A_2 \text{ 是样本二阶原点矩} \quad) \end{aligned}$$

由大数定律知,

$$A_2 = \frac{1}{n} \sum_{i=1}^n X_i^2 \text{ 依概率收敛于 } E(X^2),$$

$$\bar{X} = \frac{1}{n} \sum_{i=1}^n X_i \text{ 依概率收敛于 } E(X),$$



故 $B_2 = A_2 - \bar{X}^2$

依概率收敛于 $E(X^2) - [E(X)]^2 = \sigma^2$,

所以 B_2 是 σ^2 的相合估计量 .

又 $\lim_{n \rightarrow \infty} \frac{n}{n-1} = 1$,

所以 $S^2 = \frac{n}{n-1} B_2$ 也是 σ^2 的相合估计量 .



二 无偏性

1 无偏性的定义

定义2.1 设 $\hat{\theta} = \hat{\theta}(X_1, X_2, \dots, X_n)$ 为未知参数 θ 的一个估计量, 若

$$E(\hat{\theta}) = \theta \quad (2.1)$$

则称 $\hat{\theta}$ 为 θ 的无偏估计量, 否则称为有偏估计量。



例3.1 设总体 X 的 k 阶矩 $\mu_k = E(X^k)$ ($k \geq 1$) 存在,

又设 X_1, X_2, \dots, X_n 是 X 的一个样本, 试证明不论

总体服从什么分布, k 阶样本矩 $\overline{X^k} = \frac{1}{n} \sum_{i=1}^n X_i^k$ 是 k

阶总体矩 μ_k 的无偏估计.

证 因为 X_1, X_2, \dots, X_n 与 X 同分布,

故有 $E(X_i^k) = E(X^k) = \mu_k, \quad i = 1, 2, \dots, n.$

即 $E(\overline{X^k}) = \frac{1}{n} \sum_{i=1}^n E(X_i^k) = \mu_k.$



故 k 阶样本矩 $\overline{X^k}$ 是 k 阶总体矩 μ_k 的无偏估计 .

特别的:

不论总体 X 服从什么分布, 只要它的数学期望存在,

\overline{X} 总是总体 X 的数学期望 $\mu_1 = E(X)$ 的无偏估计量 .



例：从总体 $X \sim N(\mu, \sigma^2)$ 中取一样本 (X_1, X_2, \dots, X_n)
 $EX = \mu, DX = \sigma^2$, 试证明样本均值 \bar{X} 与样本方差 S^2
分别是 μ 及 σ^2 的无偏估计量.

证明： 设 $\hat{\mu} = \bar{X} = \frac{1}{n} \sum_{i=1}^n X_i$ 只需证明：

因为 (X_1, X_2, \dots, X_n) 是总体 $X \sim N(\mu, \sigma^2)$ 的样本.

$$X_i \sim N(\mu, \sigma^2) \quad \text{则有: } \bar{X} \sim N\left(\mu, \frac{\sigma^2}{n}\right)$$

所以: $E(\hat{\mu}) = E(\bar{X}) = \mu$



故:

$\bar{X} = \frac{1}{n} \sum_{i=1}^n X_i$ 是总体均值的无偏估计量.

下面证明样本方差 S^2 是总体方差的无偏估计量.

$$\text{设 } \hat{\sigma}^2 = S^2 = \frac{1}{n-1} \sum_{i=1}^n (X_i - \bar{X})^2$$

只需证明: $E \hat{\sigma}^2 = E S^2 = \sigma^2$



$$E \hat{\sigma}^2 = ES^2 = E\left[\frac{1}{n-1} \sum_{i=1}^n (X_i - \bar{X})^2\right]$$

$$= E\left[\frac{1}{n-1} \left(\sum_{i=1}^n X_i^2 - n\bar{X}^2\right)\right]$$

$$= \frac{1}{n-1} \left(\sum_{i=1}^n EX_i^2 - nE\bar{X}^2\right)$$

$$DX = EX^2 - (EX)^2$$

$$= \frac{1}{n-1} \left(\sum_{i=1}^n \left[DX_i + (EX_i)^2\right] - n\left[D\bar{X} + (E\bar{X})^2\right]\right)$$



$$= \frac{1}{n-1} \left(\sum_{i=1}^n \left[DX_i + (EX_i)^2 \right] - n \left[D\bar{X} + (E\bar{X})^2 \right] \right)$$

$$= \frac{1}{n-1} \left(\sum_{i=1}^n \left[\sigma^2 + \mu^2 \right] - n \left[\frac{\sigma^2}{n} + \mu^2 \right] \right)$$

$$= \frac{1}{n-1} \left(n\sigma^2 + n\mu^2 - \left[\sigma^2 + n\mu^2 \right] \right) = \sigma^2$$

故：样本方差 S^2 是总体方差的无偏估计量。



说明1:

$$S_n^2 = \frac{1}{n} \sum_{i=1}^n (X_i - \bar{X})^2 \text{ 不是无偏估计量.}$$

$$\text{因为: } ES_n^2 = E\left(\frac{1}{n} \sum_{i=1}^n (X_i - \bar{X})^2\right)$$

$$= \frac{n-1}{n} E\left(\frac{1}{n-1} \sum_{i=1}^n (X_i - \bar{X})^2\right)$$

$$= \frac{n-1}{n} \sigma^2$$



例3.3 设总体 X 在 $[0, \theta]$ 上服从均匀分布, 参数 $\theta > 0$,

X_1, X_2, \dots, X_n 是来自总体 X 的样本, 试证明 $2\bar{X}$ 和 $\frac{n}{n+1} \max(X_1, X_2, \dots, X_n)$ 都是 θ 的无偏估计.

证 因为 $E(2\bar{X}) = 2E(\bar{X}) = 2E(X) = 2 \times \frac{\theta}{2} = \theta$,

所以 $2\bar{X}$ 是 θ 的无偏估计量.

因为 $X_{(n)} = \max(X_1, X_2, \dots, X_n)$ 的概率密度为

$$f(x) = \begin{cases} \frac{nx^{n-1}}{\theta^n}, & 0 \leq x \leq \theta, \\ 0, & \text{其他} \end{cases}$$



所以 $E(X_{(n)}) = \int_0^\theta x \cdot \frac{nx^{n-1}}{\theta^n} dx$

$$= \frac{n}{n+1} \theta,$$

故有 $E\left(\frac{n+1}{n} X_{(n)}\right) = \theta,$

故 $\frac{n}{n+1} \max(X_1, X_2, \dots, X_n)$ 也是 θ 的无偏估计量 .



2 渐近无偏估计

定义3.2 若 $\hat{\theta}_n$ 为 θ 的有偏估计量，但有

$$\lim_{n \rightarrow \infty} E(\hat{\theta}_n) = \theta \quad (2.2)$$

则称 $\hat{\theta}_n$ 为 θ 的渐近无偏估计量。

例3.4 样本二阶中心矩 S_n^2 是 σ^2 的渐近无偏估计量。



注: 如果 $\hat{\theta}$ 是参数 θ 的一个估计, 我们常用 $g(\hat{\theta})$ 作为 $g(\theta)$ 的估计. 但当 $\hat{\theta}$ 是 θ 的无偏估计时, $g(\hat{\theta})$ 未必是 $g(\theta)$ 的无偏估计.

例如, 样本标准差 S 不是总体标准差 σ 的无偏估计.

$$\because E(S^2) = \sigma^2 \quad \therefore D(S) + E^2(S) = \sigma^2$$

$$\because D(S) \geq 0 \quad \therefore E^2(S) = \sigma^2 - D(S) \leq \sigma^2$$

$$\therefore E(S) \leq \sigma$$

即: 一般说 S 不是 σ 的无偏估计

无偏估计量的函数未必是无偏估计量



设总体 X 的方差 $D(X)$ 存在, 且 $D(X) > 0$,
 (X_1, X_2, \dots, X_n) 为来自总体 X 的样本, 试选择适当的常数 C , 使得

$$C \sum_{i=1}^{n-1} (X_{i+1} - X_i)^2$$

为 $D(X)$ 的无偏估计.

解 \because

$$\begin{aligned} E\left[C \sum_{i=1}^{n-1} (X_{i+1} - X_i)^2\right] &= C \sum_{i=1}^{n-1} E(X_{i+1} - X_i)^2 \\ &= C \sum_{i=1}^{n-1} \{D(X_{i+1} - X_i) + [E(X_{i+1} - X_i)]^2\} \end{aligned}$$



而 X_1, X_2, \dots, X_n 相互独立, 且与 X 同分布

$$\therefore E(X_i) = E(X), \quad D(X_i) = D(X) \quad (i = 1, 2, \dots, n)$$

$$D(X_{i+1} - X_i) = D(X_{i+1}) + D(X_i) = 2D(X)$$

$$E(X_{i+1} - X_i) = E(X_{i+1}) - E(X_i) = 0$$

$$\begin{aligned} \therefore E[C \sum_{i=1}^{n-1} (X_{i+1} - X_i)^2] \\ &= C \sum_{i=1}^{n-1} \{D(X_{i+1} - X_i) + [E(X_{i+1} - X_i)]^2\} \\ &= C \sum_{i=1}^{n-1} 2D(X) = C \cdot 2(n-1)D(X) \end{aligned}$$

依题意，要求： $E[C \sum_{i=1}^{n-1} (X_{i+1} - X_i)^2] = D(X)$

$$\text{即 } C \cdot 2(n-1)D(X) = D(X)$$

$$\because D(X) > 0 \quad \therefore C = \frac{1}{2(n-1)}.$$



三、有效性

比较参数 θ 的两个无偏估计量 $\hat{\theta}_1$ 和 $\hat{\theta}_2$,如果在样本容量 n 相同的情况下, $\hat{\theta}_1$ 的观察值在真值 θ 的附近较 $\hat{\theta}_2$ 更密集,则认为 $\hat{\theta}_1$ 较 $\hat{\theta}_2$ 有效.

由于方差是随机变量取值与其数学期望的偏离程度,所以无偏估计以方差小者为好.



1 有效方差

定义3.3 设 $\hat{\theta}_1$ 与 $\hat{\theta}_2$ 是 θ 的无偏估计量, 若

$$D(\hat{\theta}_1) < D(\hat{\theta}_2) \quad (2.3)$$

则称 $\hat{\theta}_1$ 较 $\hat{\theta}_2$ 有效。



例7 (续例4) 在例 4中已证明 $\hat{\theta}_1 = 2\bar{X}$

和 $\hat{\theta}_2 = \frac{n+1}{n} \max\{X_1, X_2, \dots, X_n\}$ 都是 θ 的无偏估计

计量, 现证当 $n \geq 2$ 时, $\hat{\theta}_2$ 较 $\hat{\theta}_1$ 有效.

证明 由于 $D(\hat{\theta}_1) = 4D(\bar{X}) = \frac{4}{n} D(X) = \frac{\theta^2}{3n},$

$$D(\hat{\theta}_2) = D\left(\frac{n+1}{n} X_{(n)}\right) = \left(\frac{n+1}{n}\right)^2 D(X_{(n)}),$$

又因为 $E(X_{(n)}) = \frac{n+1}{n} \theta,$



$$E(X_{(n)}^2) = \int_0^\theta \frac{n}{\theta^n} x^{n+1} dx = \frac{n}{n+2} \theta^2,$$

$$D(X_{(n)}) = E(X_{(n)}^2) - [E(X_{(n)})]^2$$

$$= \frac{n}{(n+1)^2(n+2)} \theta^2,$$

$$\text{故 } D(\hat{\theta}_2) = \frac{1}{n(n+2)} \theta^2,$$

又 $n \geq 2$, 所以 $D(\hat{\theta}_2) < D(\hat{\theta}_1)$, $\hat{\theta}_2$ 较 $\hat{\theta}_1$ 有效.



例3 设总体 X 的均值和方差均存在, X_1, \dots, X_n 是总体 X 的样本,
 C_1, C_2, \dots, C_n 为不全相同且满足 $\sum_{i=1}^n C_i = 1$ 的任一组常数,

证明: (1) 样本的线性函数 $\sum_{i=1}^n C_i X_i$ 是总体均值 μ 的无偏估计量;
(2) 总体均值的无偏估计量 $\bar{X} = \frac{1}{n} \sum_{i=1}^n X_i$ 较 $\sum_{i=1}^n C_i X_i$ 有效.

证 (1) $\because E(\sum_{i=1}^n C_i X_i) = \sum_{i=1}^n C_i \cdot EX_i = \mu \sum_{i=1}^n C_i = \mu$
 $\therefore \sum_{i=1}^n C_i X_i$ 是 μ 的无偏估计量;

(2) 由柯西—许瓦兹不等式知

$$1 = (\sum_{i=1}^n C_i)^2 < \sum_{i=1}^n 1^2 \cdot \sum_{i=1}^n C_i^2 = n \sum_{i=1}^n C_i^2 \quad \Rightarrow \quad \sum_{i=1}^n C_i^2 > \frac{1}{n}$$

$$\therefore D(\sum_{i=1}^n C_i X_i) = \sum_{i=1}^n C_i^2 \cdot DX_i = \sigma^2 \sum_{i=1}^n C_i^2 > \frac{\sigma^2}{n} = D\bar{X}.$$

这表明, 在 μ 的所有线性无偏估计量中, 样本均值 \bar{X} 是最有效的.

例4 设 X_1, X_2, \dots, X_n 和 Y_1, Y_2, \dots, Y_m 是两组随机样本,分别取自总体 $X \sim N(\mu, 1)$ 和 $Y \sim N(\mu, 2^2)$,

$$T = a \sum_{i=1}^n X_i + b \sum_{j=1}^m Y_j.$$

(1)当 a, b 满足什么关系时, T 是 μ 的无偏估计?

(2)当 a, b 分别取何值时, T 最有效?

解:(1) $E(T) = a \cdot n\mu + b \cdot m\mu = (na + mb)\mu$

\Rightarrow 当 $na + mb = 1$ 时, $E(T) = \mu$

此时, T 是 μ 的无偏估计



$$(2) D(T) = a^2 \cdot n + b^2 \cdot 4m = na^2 + 4m \left(\frac{1 - na}{m} \right)^2$$

$$= na^2 + \frac{4(1 - na)^2}{m}$$

$$\text{令 } \frac{dD}{da} = 0 \Rightarrow 2na - \frac{8n(1 - na)}{m} = 0$$

$$\Rightarrow (4n + m)a = 4 \Rightarrow a = \frac{4}{4n + m}$$

$D''(a) > 0 \Rightarrow$ 此时 $D(T)$ 最小, 即 T 最有效

$$\therefore a = \frac{4}{4n + m}, \quad b = \frac{1}{4n + m}$$



6.2.4 均方误差

在均方误差的标准下，无偏估计不一定比有偏估计更优。

评价一个点估计的好坏一般可以用：点估计值与参数真值 θ 的距离平方的期望，这就是下式给出的均方误差

$$MSE(\hat{\theta}) = E(\hat{\theta} - \theta)^2$$

均方误差是评价点估计的最一般的标准。我们希望估计的均方误差越小越好。



注意到 $MSE(\hat{\theta}) = \text{Var}(\hat{\theta}) + (E\hat{\theta} - \theta)^2$, 因此

- (1) 若 $\hat{\theta}$ 是 θ 的无偏估计, $MSE(\hat{\theta}) = \text{Var}(\hat{\theta})$,
这说明用方差考察无偏估计有效性是合理的。
- (2) 当 $\hat{\theta}$ 不是 θ 的无偏估计时, 就要看其均方误差 $MSE(\hat{\theta})$ 。

下面的例子说明: 在均方误差的含义下有些有偏估计优于无偏估计。



例6.2.8 对均匀总体 $U(0, \theta)$, 由 θ 的极大似然估计得到的

无偏估计是 $\hat{\theta} = \frac{(n+1)}{n} X_{(n)}$, 它的均方误差

$$MSE(\hat{\theta}) = \text{Var}(\hat{\theta}) = \frac{\theta^2}{n(n+2)}$$

现我们考虑 θ 的形如 $\hat{\theta}_\alpha = \alpha \cdot x_{(n)}$ 的估计, 其均方差为

$$MSE(\hat{\theta}_\alpha) = \alpha^2 \frac{n}{(n+1)^2(n+2)} \theta^2 + \left(\frac{n \cdot \alpha}{n+1} - 1 \right)^2 \theta^2$$

用求导的方法不难求出当 $\alpha_0 = (n+2)/(n+1)$ 时上述均方误差达到最小, 且其均方误差

$$MSE(\hat{\theta}_0) = \frac{\theta^2}{(n+1)^2} < \frac{\theta^2}{n(n+2)} = MSE(\hat{\theta})$$

所以 在均方误差的标准下, 有偏估计 $\hat{\theta}_0$ 优于无偏估计 $\hat{\theta}$ 。



6.4.2 最小方差无偏估计

定义6.4.2 对参数估计问题，设 $\hat{\theta}$ 是 θ 的一个无偏估计，如果对另外任意一个 θ 的无偏估计 $\tilde{\theta}$ ，在参数空间 Θ 上都有

$$\text{Var}_{\theta}(\hat{\theta}) \leq \text{Var}_{\theta}(\tilde{\theta})$$

则称 $\hat{\theta}$ 是 θ 的一致最小方差无偏估计简记为 **UMVUE**。



1 最小方差无偏估计的判别法

定理6.4.1 设 $X=(X_1, X_2, \dots, X_n)$ 是来自某总体的一个样本, $\hat{\theta} = \hat{\theta}(x)$ 是 θ 的一个无偏估计, $\text{Var}(\hat{\theta}) < \infty$. 如果对任意一个满足 $E(\phi(X))=0$ 的 $\phi(X)$, 都有

$$\text{Cov}_{\theta}(\hat{\theta}, \phi) = 0, \quad \forall \theta \in \Theta$$

则 $\hat{\theta}$ 是 θ 的UMVUE。



注

- 1 此定理是最小方差无偏估计的判别法，但无法寻求最小方差无偏估计的存在性.
- 2 由于 $\phi(X)$ 的任意性，因而很难利用定理判别.

由下例可以看出，利用判别定理进行判别，非常复杂，况且也无法利用此定理去寻求 **UMVUE**.



例6.4.2 设 X_1, X_2, \dots, X_n 是来自指数分布 $\text{Exp}(1/\theta)$ 的样本, 则 $T = X_1 + \dots + X_n$ 是 θ 的充分统计量, $\bar{X} = T / n$ 是 θ 的无偏估计。设 $\varphi = \varphi(X_1, X_2, \dots, X_n)$ 是 θ 的任一
无偏估计, 则
$$\int_0^\infty \dots \int_0^\infty \varphi(x_1, \dots, x_n) \cdot e^{-(x_1 + \dots + x_n)/\theta} dx_1 \dots dx_n = 0$$

两端对 θ 求导得

$$\int_0^\infty \dots \int_0^\infty \frac{n\bar{x}}{\theta^2} \varphi(x_1, \dots, x_n) \cdot e^{-(x_1 + \dots + x_n)/\theta} dx_1 \dots dx_n = 0$$

这说明 $E(\bar{x} \cdot \varphi) = 0$, 从而 $\text{Cov}(\bar{x}, \varphi) = E(\bar{x} \cdot \varphi) - E(\bar{x}) \cdot E(\varphi) = 0$,
由定理6.4.1, 它是 θ 的UMVUE。



例

设 $X = (X_1, X_2, \dots, X_n)^T$ 是来自总体 (μ, σ^2) 的一个样本，已知 \bar{X} 和 S_n^{*2} 是 μ 和 σ^2 的无偏估计，证明 \bar{X} 和 S_n^{*2} 分别是 μ 和 σ^2 的 *MVUE*。

证 设 $L(X)$ 满足 $EL(X) = 0$, 则

$$\int \cdots \int L \cdot \exp\left\{-\frac{1}{2\sigma^2} \sum_{i=1}^n (x_i - \mu)^2\right\} d\mathbf{x} = 0$$

两边关于 μ 求导，则

$$\int \cdots \int L \cdot \sum_{i=1}^n x_i \cdot \exp\left\{-\frac{1}{2\sigma^2} \sum_{i=1}^n (x_i - \mu)^2\right\} d\mathbf{x} = 0$$

因而 $E(L(X)\bar{X}) = 0$



故 \bar{X} 是 μ 的 *MVUE* .

对此式 $\int \cdots \int L \cdot \exp\left\{-\frac{1}{2\sigma^2} \sum_{i=1}^n (x_i - \mu)^2\right\} \mathrm{d}x = 0$ 关于 μ

求二阶导数，则

$$\int \cdots \int L \cdot \left(\sum_{i=1}^n x_i\right)^2 \exp\left\{-\frac{1}{2\sigma^2} \sum_{i=1}^n (x_i - \mu)^2\right\} \mathrm{d}x = 0$$

对此式 $\int \cdots \int L \cdot \exp\left\{-\frac{1}{2\sigma^2} \sum_{i=1}^n (x_i - \mu)^2\right\} \mathrm{d}x = 0$ 关于 σ^2

求导数，则

$$\int \cdots \int L \cdot \sum_{i=1}^n (x_i - \mu)^2 \exp\left\{-\frac{1}{2\sigma^2} \sum_{i=1}^n (x_i - \mu)^2\right\} \mathrm{d}x = 0$$



又由于 $\sum_{i=1}^n (x_i - \bar{x})^2 = \sum_{i=1}^n (x_i - \mu)^2 - n(\bar{x} - \mu)^2$, 可得

$$\int \cdots \int L \cdot \sum_{i=1}^n (x_i - \bar{x})^2 \exp\left\{-\frac{1}{2\sigma^2} \sum_{i=1}^n (x_i - \mu)^2\right\} d\mathbf{x} = 0$$

因而 $E(L(X)S_n^{*2}) = 0$

故 S_n^{*2} 是 σ^2 的 *MVUE*.



6.4.2 充分性原则

以下定理说明：充分统计量是一个有力工具

定理6.4.2 设总体概率函数是 $f(x, \theta)$, X_1, X_2, \dots, X_n 是其样本, $T=T(X_1, X_2, \dots, X_n)$ 是 θ 的充分统计量, 则

对 θ 的任一无偏估计 $\hat{\theta} = \hat{\theta}(x_1, \dots, x_n)$, 令 $\tilde{\theta} = E(\hat{\theta} | T)$, $\tilde{\theta}$ 也是 θ 的无偏估 $\text{Var}(\tilde{\theta}) \leq \text{Var}(\hat{\theta})$



定理6.4.2说明：如果无偏估计不是充分统计量的函数，则将之对充分统计量求条件期望可以得到一个新的无偏估计，该估计的方差比原来的估计的方差要小，从而降低了无偏估计的方差。换言之，考虑 θ 的估计问题只需要在基于充分统计量的函数中进行即可，该说法对所有的统计推断问题都是正确的，这便是所谓的充分性原则。



注 最小方差无偏估计计算方法

- 1、构造一个充分完备统计量 $T(X_1, \dots, X_n)$ 和一个 θ 的无偏估计 $\hat{\theta}$.
- 2、计算数学期望 $E(\hat{\theta} | T)$, 即得 θ 的一个 $MVUE$.



例6.3.1 设 x_1, x_2, \dots, x_n 是来自 $b(1, p)$ 的样本, 则 $T = n\bar{x}$ 是 p 的充分统计量。为估计 $\theta = p^2$, 可令

$$\hat{\theta}_1 = \begin{cases} 1, & x_1 = 1, x_2 = 1 \\ 0, & \text{其它} \end{cases}$$

由于 $E(\hat{\theta}_1) = P(x_1 = 1, x_2 = 1) = p \cdot p = \theta$, 所以 $\hat{\theta}_1$ 是 θ 的无偏估计。这个只使用了两个观测值的估计并不好。下面我们用Rao-Blackwell定理对之加以改进: 求 $\hat{\theta}_1$ 关于充分统计量的条件期望, 得 $T = \sum_{i=1}^n x_i$

$$\hat{\theta} = E(\hat{\theta}_1 | T = t) = \frac{\binom{n-2}{t-2}}{\binom{n}{t}} = \frac{t(t-1)}{n(n-1)}$$



6.4.4 Cramer-Rao不等式

上一节介绍了最小方差无偏估计以及相应的寻求方法。自然会引入另一个问题：最小方差无偏估计是否可以任意的小？是否有下界？事实上，**Rao-Cramer不等式**可以回答此问题。



定义6.4.3 设总体的概率函数 $P(x, \theta)$,
 $\theta \in \Theta$ 满足下列条件:

- (1) 参数空间 Θ 是直线上的一个开区间;
- (2) 支撑 $S = \{x: P(x, \theta) > 0\}$ 与 θ 无关;
- (3) 导数 $\frac{\partial}{\partial \theta} p(x; \theta)$ 对一切 $\theta \in \Theta$ 都存在;
- (4) 对 $P(x, \theta)$, 积分与微分运算可交换次序;
- (5) 期望 $E \left[\frac{\partial}{\partial \theta} \ln p(x; \theta) \right]^2$ 存在;

则称 $I(\theta) = E \left[\frac{\partial}{\partial \theta} \ln p(x; \theta) \right]^2$

为总体分布的费希尔(Fisher) 信息量。



费希尔信息量是数理统计学中一个基本概念，很多的统计结果都与费希尔信息量有关。如极大似然估计的渐近方差，无偏估计的方差的下界等都与费希尔信息量 $I(\theta)$ 有关。



例6.3.3 设总体为泊松分布 $P(\lambda)$ 分布,

则 $\ln p(x; \lambda) = x \ln \lambda - \lambda - \ln(x!)$

$$\frac{\partial}{\partial \lambda} \ln p(x; \lambda) = \frac{x}{\lambda} - 1$$

$$\text{于是 } I(\lambda) = E \left(\frac{X - \lambda}{\lambda} \right)^2 = \frac{1}{\lambda}$$



例6.3.4 设总体为指数分布，其密度函数为

$$p(x; \theta) = \frac{1}{\theta} \exp \left\{ -\frac{x}{\theta} \right\}, \quad x > 0, \theta > 0$$

可以验证定义6.3.2的条件满足，且

$$\frac{\partial}{\partial \theta} \ln p(x; \theta) = \frac{1}{\theta} - \frac{x}{\theta^2} = -\frac{x - \theta}{\theta^2}$$

于是

$$I(\theta) = E \left(\frac{x - \theta}{\theta^2} \right)^2 = \frac{\text{Var}(x)}{\theta^4} = \frac{1}{\theta^2}$$



定理6.3.4 (Cramer-Rao不等式)

设定义6.3.2的条件满足, X_1, X_2, \dots, X_n 是来自该总体的样本, $T=T(X_1, X_2, \dots, X_n)$ 是 $g(\theta)$ 的任一个无偏估计, $g'(\theta) = \frac{\partial g(\theta)}{\partial \theta}$ 存在, 且对 $\theta \in \Theta$ 中一切 θ , 微分可在积分号下进行, 则有

$$\text{Var}(T) \geq \frac{[g'(\theta)]^2}{nI(\theta)}$$



- 上式称为克拉美-罗 (C-R) 不等式;
- $[g'(\vartheta)]^2/(nI(\theta))$ 称为 $g(\theta)$ 的无偏估计的方差的C-R下界, 简称 $g(\theta)$ 的C-R下界。
- 特别, 对 θ 的无偏估计 $\hat{\theta}$, 有 $\text{Var}(\hat{\theta}) \geq (nI(\theta))^{-1}$
- 如果等号成立, 则称 $T=T(x_1, \dots, x_n)$ 是 $g(\theta)$ 的有效估计, 有效估计一定是 **UMVUE**。



例6.4.6 设总体分布列为 $p(x, \theta) = \theta^x (1-\theta)^{1-x}$,

$x=0,1$, 它满足定义6.4.3的所有条件, 可以算得该分布的费希尔信息量 $I(\theta) = \frac{1}{\theta(1-\theta)}$, 若 x_1, x_2, \dots, x_n 是该总体的样本, 则 θ 的C-R下界为 $(nI(\theta))^{-1} = \theta(1-\theta)/n$ 。因为 \bar{x} 是 θ 的无偏估计, 且其方差等于 $\theta(1-\theta)/n$, 达到C-R下界, 所以 \bar{x} 是 θ 的有效估计, 它也是 θ 的UMVUE。



例6.4.7 设总体为指数分布 $Exp(1/\theta)$ ，它满足定义6.3.2的所有条件，例6.3.4中已经算出该分布的费希尔信息量为 $I(\theta) = \theta^{-2}$ ，若 x_1, x_2, \dots, x_n 是样本，则 θ 的C-R下界为 $(nI(\theta))^{-1} = \theta^2/n$ 。而 \bar{x} 是 θ 的无偏估计，且其方差等于 θ^2/n ，达到了C-R下界，所以， \bar{x} 是 θ 的有效估计，它也是 θ 的UMVUE。



能达到C-R下界的无偏估计不多：

例6.4.8 设总体为 $N(0, \sigma^2)$ ，满足定义6.3.2的条件，且费希尔信息量为 $I(\sigma^2) = \frac{1}{2\sigma^4}$ ，

令 $\sigma = g(\sigma^2) = \sqrt{\sigma^2}$ ，

则 σ 的C-R下界为 $\frac{[g'(\sigma^2)]^2}{nI(\sigma^2)} = \frac{\sigma^2}{2n}$ ，

而 σ 的UMVUE为 $\hat{\sigma} = \sqrt{\frac{n}{2}} \cdot \frac{\Gamma(n/2)}{\Gamma((n+1)/2)} \sqrt{\frac{1}{n} \sum_{i=1}^n x_i^2}$

其方差大于C-R下界。这表明所有 σ 的无偏估计的方差都大于其C-R下界。



费希尔信息量的主要作用体现在极大似然估计。

定理6.3.5 设总体 X 有密度函数 $p(x; \theta)$, $\theta \in \Theta$, Θ 为非退化区间, 假定

(1) 对任意的 x , 偏导数 $\frac{\partial \ln p}{\partial \theta}$, $\frac{\partial^2 \ln p}{\partial \theta^2}$ 和 $\frac{\partial^3 \ln p}{\partial \theta^3}$ 对所有 $\theta \in \Theta$ 都存在;

(2) $\forall \theta \in \Theta$,
有 $\left| \frac{\partial p}{\partial \theta} \right| < F_1(x)$, $\left| \frac{\partial^2 p}{\partial \theta^2} \right| < F_2(x)$, $\left| \frac{\partial^3 \ln p}{\partial \theta^3} \right| < F_3(x)$,

其中函数 $F_1(x)$, $F_2(x)$, $F_3(x)$ 可积.



$$(3) \quad \forall \theta \in \Theta, \quad 0 < I(\theta) \equiv \int_{-\infty}^{\infty} \left(\frac{\partial \ln p}{\partial \theta} \right)^2 p(x; \theta) dx < \infty$$

若 x_1, x_2, \dots, x_n 是来自该总体的样本，
则存在未知参数 θ 的极大似然估计 $\hat{\theta}_n = \hat{\theta}_n(x_1, \dots, x_n)$ ，且 $\hat{\theta}_n$ 具有相合性和渐近正态性：

$$\hat{\theta}_n \underset{\sim}{\sim} N \left(\theta, \frac{1}{nI(\theta)} \right)$$



定理

设总体 X 的分布函数为 $F(x, \theta)$, $\theta \in \Theta$ 是未知参数, $X = (X_1, X_2, \dots, X_n)^T$ 是来自总体 X 的一个样本, 如果 $\hat{\theta} = \hat{\theta}(X_1, X_2, \dots, X_n)$ 是 θ 的无偏估计量, 则 $\hat{\theta}$ 是 θ 的有效估计的充分必要条件为:

1、 $\hat{\theta}$ 是 θ 的充分估计量;

$$2、\frac{\partial \ln L(x, \theta)}{\partial \theta} = C(\theta)[\hat{\theta}(x_1, x_2, \dots, x_n) - \theta]$$

其中 $L(x, \theta)$ 是样本的联合分布密度, $C(\theta)$ 仅依赖参数 θ .

证明从略。



例

设 X 服从两点分布 $B(1, p)$, $X_1,$

X_2, \dots, X_n 是来自 X 的一个样本, 证明 p 的最大似然估计量是有效估计.

解 因为 X 的分布律为

$$P\{X = x\} = p^x (1 - p)^{1-x} \quad (x = 0, 1)$$

所以 p 的似然函数为

$$L(p) = \prod_{i=1}^n \left(p^{x_i} (1 - p)^{1-x_i} \right) = p^{\sum_{i=1}^n x_i} (1 - p)^{n - \sum_{i=1}^n x_i}$$



$$\ln L(p) = \left(\sum_{i=1}^n x_i \right) p - \left(n - \sum_{i=1}^n x_i \right) (1 - p),$$

$$\frac{d}{dp} \ln L(p) = \frac{\sum_{i=1}^n x_i}{p} - \frac{n - \sum_{i=1}^n x_i}{1 - p} = \frac{n}{p(1 - p)} \{ \bar{x} - p \} = 0$$

解得 p 的最大似然估计值 $\hat{p} = \frac{1}{n} \sum_{i=1}^n x_i = \bar{x},$

又因为 $\frac{\partial \ln L(x, p)}{\partial p} = C(p) [\hat{p}(x_1, x_2, \dots, x_n) - p],$ 其中

$$C(p) = \frac{n}{p(1 - p)},$$

同时 \bar{X} 是 p 的充分统计量, 因而由

定理 3.11 可知, \bar{X} 是 p 的有效估计.



§ 6.4 贝叶斯估计

6.4.1 统计推断的基础

- 经典学派的观点：统计推断是根据样本信息对总体分布或总体的特征数进行推断，这里用到两种信息：总体信息和样本信息；
- 贝叶斯学派的观点：除了上述两种信息以外，统计推断还应该使用第三种信息：先验信息。



- (1) 总体信息:总体分布提供的信息。
- (2) 样本信息:抽取样本所得观测值提供的信息。
- (3) 先验信息:人们在试验之前对要做的问题在经验上和资料上总是有所了解的, 这些信息对统计推断是有益的。先验信息即是抽样(试验)之前有关统计问题的一些信息。一般说来, 先验信息来源于经验和历史资料。先验信息在日常生活和工作中是很重要的。



基于上述三种信息进行统计推断的统计学称为贝叶斯统计学。它与经典统计学的差别就在于是否利用先验信息。贝叶斯统计在重视使用总体信息和样本信息的同时，还注意先验信息的收集、挖掘和加工，使它数量化，形成先验分布，参加到统计推断中来，以提高统计推断的质量。忽视先验信息的利用，有时是一种浪费，有时还会导出不合理的结论。



贝叶斯学派的基本观点：任一未知量 θ 都可看作随机变量，可用一个概率分布去描述，这个分布称为先验分布；在获得样本之后，总体分布、样本与先验分布通过贝叶斯公式结合起来得到一个关于未知量 θ 新的分布——后验分布；任何关于 θ 的统计推断都应该基于 θ 的后验分布进行。



6.4.2 贝叶斯公式的密度函数形式

- 总体 X 依赖于参数 θ 的概率函数在贝叶斯统计中记为 $f(X | \theta)$ ，它表示在随机变量 θ 取某个给定值时总体的条件概率函数；
- 根据参数 θ 的先验信息可确定先验分布 $\pi(\theta)$ ；
- 从贝叶斯观点看，样本 X_1, X_2, \dots, X_n 的产生分两步进行：首先从先验分布 $\pi(\theta)$ 产生一个样本 θ_0 ，然后从 $f(X | \theta_0)$ 中产生一组样本。这时样本的联合条件概率函数为
$$p(X_1, \dots, X_n | \theta_0) = \prod_{i=1}^n f(X_i | \theta_0),$$
- 这个分布综合了总体信息和样本信息；



➤ θ_0 是未知的，它是按先验分布 $\pi(\theta)$ 产生的。为把先验信息综合进去，不能只考虑 θ_0 ，对 θ 的其它值发生的可能性也要加以考虑，故要用 $\pi(\theta)$ 进行综合。这样一来，样本 X_1, \dots, X_n 和参数 θ 的联合分布为：

$$h(X_1, X_2, \dots, X_n, \theta) = f(X_1, X_2, \dots, X_n | \theta) \pi(\theta),$$

这个联合分布把总体信息、样本信息和先验信息三种可用信息都综合进去了；



- 在没有样本信息时，人们只能依据先验分布对 θ 作出推断。在有了样本观察值 x_1, x_2, \dots, x_n 之后，则应依据 $h(x_1, x_2, \dots, x_n, \theta)$ 对 θ 作出推断。由于

$$h(x_1, x_2, \dots, x_n, \theta) = \pi(\theta | x_1, x_2, \dots, x_n) m(x_1, x_2, \dots, x_n),$$

其中 $m(x_1, \dots, x_n) = \int_{\Theta} h(x_1, \dots, x_n, \theta) d\theta = \int_{\Theta} p(x_1, \dots, x_n | \theta) \pi(\theta) d\theta$

是 x_1, x_2, \dots, x_n 的边际概率函数，它与 θ 无关，不含 θ 的任何信息。因此能用来对 θ 作出推断的仅是条件分布 $\pi(\theta | x_1, x_2, \dots, x_n)$ ，它的计算公式是

$$\pi(\theta | x_1, \dots, x_n) = \frac{h(x_1, \dots, x_n, \theta)}{m(x_1, \dots, x_n)} = \frac{p(x_1, \dots, x_n | \theta) \pi(\theta)}{\int_{\Theta} p(x_1, \dots, x_n | \theta) \pi(\theta) d\theta}$$



这个条件分布称为 θ 的后验分布，它集中了总体、样本和先验中有关 θ 的一切信息。

后验分布 $\pi(\theta|x_1, x_2, \dots, x_n)$ 的计算公式就是用密度函数表示的贝叶斯公式。它是用总体和样本对先验分布 $\pi(\theta)$ 作调整的结果，贝叶斯统计的一切推断都基于后验分布进行。



6.4.3 贝叶斯估计

基于后验分布 $\pi(\theta | x_1, x_2, \dots, x_n)$ 对 θ 所作的贝叶斯估计有多种，常用有如下三种：

- 使用后验分布的密度函数最大值作为 θ 的点估计，称为最大后验估计；
- 使用后验分布的中位数作为 θ 的点估计，称为后验中位数估计；
- 使用后验分布的均值作为 θ 的点估计，称为后验期望估计。

用得最多的是后验期望估计，它一般也简称为贝叶斯估计，记为 $\hat{\theta}_B$ 。



例6.4.2 设某事件A在一次试验中发生的概率为 θ ，为估计 θ ，对试验进行了 n 次独立观测，其中事件A发生了 x 次，显然 $X|\theta \sim b(n, \theta)$ ，即

$$P(X = x | \theta) = \binom{n}{x} \theta^x (1 - \theta)^{n-x}, \quad x = 0, 1, \dots, n$$

假若我们在试验前对事件A没有什么了解，从而对其发生的概率 θ 也没有任何信息。在这种场合，贝叶斯本人建议采用“同等无知”的原则使用区间 $(0,1)$ 上的均匀分布 $U(0,1)$ 作为 θ 的先验分布，因为它取 $(0,1)$ 上的每一点的机会均等。贝叶斯的这个建议被后人称为贝叶斯假设。



由此即可利用贝叶斯公式求出 θ 的后验分布。具体如下：

先写出 X 和 θ 的联合分布

$$h(x, \theta) = \binom{n}{x} \theta^x (1 - \theta)^{n-x}, \quad x = 0, 1, \dots, n, \quad 0 < \theta < 1$$

然后求 X 的边际分布

$$m(x) = \int_0^1 \binom{n}{x} \theta^x (1 - \theta)^{n-x} d\theta = \binom{n}{x} \frac{\Gamma(x+1)\Gamma(n-x+1)}{\Gamma(n+2)}$$

最后求出 θ 的后验分布

$$\pi(\theta | x) = \frac{h(x, \theta)}{m(x)} = \frac{\Gamma(n+2)}{\Gamma(x+1)\Gamma(n-x+1)} \theta^{(x+1)-1} (1-\theta)^{(n-x+1)-1}, \quad 0 < \theta < 1$$

最后的结果说明 $\theta | X \sim \text{Be}(x+1, n-x+1)$ ，其后验期望估计为

$$\hat{\theta}_B = E(\theta | x) = \frac{x+1}{n+2} \quad (6.4.4)$$



伽玛函数表达式:

$$\Gamma(x) = \int_0^{+\infty} e^{-t} t^{(x-1)} dt = (x-1)\Gamma(x-1)$$

$$\Gamma(1) = 1, \Gamma(n+1) = n!$$

U(0,1)均匀分布是贝塔分布的一个特例**Be (1, 1)**



某些场合，贝叶斯估计要比极大似然估计更合理一点。比如：“抽检3个全是合格品”与“抽检10个全是合格品”，后者的质量比前者更信得过。这种差别在不合格品率的极大似然估计中反映不出来（两者都为0），而用贝叶斯估计两者分别是0.2 和 0.83。

由此可以看到，在这些极端情况下，贝叶斯估计比极大似然估计更符合人们的理念。



例6.4.3 设 x_1, x_2, \dots, x_n 是来自正态分布

$N(\mu, \sigma_0^2)$ 的一个样本，其中 σ_0^2 已知， μ 未知，假设 μ 的先验分布亦为正态分布 $N(\theta, \tau^2)$ ，其中先验均值 θ 和先验方差 τ^2 均已知，试求 μ 的贝叶斯估计。

解：样本 x 的分布和 μ 的先验分布分别为

$$p(x | \mu) = (2\pi\sigma_0^2)^{-n/2} \exp \left\{ -\frac{1}{2\sigma_0^2} \sum_{i=1}^n (x_i - \mu)^2 \right\}$$

$$\pi(\mu) = (2\pi\tau^2)^{-1/2} \exp \left\{ -\frac{1}{2\tau^2} (\mu - \theta)^2 \right\}$$



由此可以写出 x 与 μ 的联合分布

$$h(\mathbf{X}, \mu) = k_1 \cdot \exp \left\{ -\frac{1}{2} \left[\frac{n\mu^2 - 2n\mu\bar{x} + \sum_{i=1}^n x_i^2}{\sigma_0^2} + \frac{\mu^2 - 2\theta\mu + \theta^2}{\tau^2} \right] \right\}$$

其中 $\bar{x} = \frac{1}{n} \sum_{i=1}^n x_i$, $k_1 = (2\pi)^{-(n+1)/2} \tau^{-1} \sigma_0^{-n}$ 。若记

$$A = \frac{n}{\sigma_0^2} + \frac{1}{\tau^2}, \quad B = \frac{n\bar{x}}{\sigma_0^2} + \frac{\theta}{\tau^2}, \quad C = \frac{\sum_{i=1}^n x_i^2}{\sigma_0^2} + \frac{\theta^2}{\tau^2}$$

则有

$$\begin{aligned} h(\mathbf{X}, \mu) &= k_1 \exp \left\{ -\frac{1}{2} [A\mu^2 - 2B\mu + C] \right\} \\ &= k_1 \exp \left\{ -\frac{(\mu - B/A)^2}{2/A} - \frac{1}{2} (C - B^2/A) \right\} \end{aligned}$$



注意到 A, B, C 均与 μ 无关，由此容易算得样本的边际密度函数

$$m(x) = \int_{-\infty}^{\infty} h(x, \mu) d\mu = k_1 \exp \left\{ -\frac{1}{2} (C - B^2 / A) \right\} (2\pi / A)^{1/2}$$

应用贝叶斯公式即可得到后验分布

$$\pi(\mu | x) = \frac{h(x, \mu)}{m(x)} = (2\pi / A)^{1/2} \exp \left\{ -\frac{1}{2/A} (\mu - B / A)^2 \right\}$$

这说明在样本给定后， μ 的后验分布为

$$N(B/A, 1/A), \quad \text{即} \quad \mu | x \sim N \left(\frac{n\bar{x}\sigma_0^{-2} + \theta\tau^{-2}}{n\sigma_0^{-2} + \tau^{-2}}, \frac{1}{n\sigma_0^{-2} + \tau^{-2}} \right)$$



后验均值即为其贝叶斯估计：

$$\hat{\mu} = \frac{n / \sigma_0^2}{n / \sigma_0^2 + 1 / \tau^2} \bar{x} + \frac{1 / \tau^2}{n / \sigma_0^2 + 1 / \tau^2} \theta$$

它是样本均值 \bar{x} 与先验均值 θ 的加权平均。



6.4.4 共轭先验分布

若后验分布 $\pi(\theta|x)$ 与 $\pi(\theta)$ 属于同一个分布族，则称该分布族是 θ 的共轭先验分布(族)。

- 后验分布和先验分布是同一个类型
- 优点：易于解释、继续试验
- 已知： $p(x|\theta)$ ，选 $\pi(\theta)$
- 使得 $h(\theta|r) \propto p(x|\theta) * \pi(\theta)$ 与先验分布同类型
- 若 $p(x|\theta)$ 服从正态分布，选正态分布
- 若 $p(x|\theta)$ 服从两点分布，选Beta分布
- 若 $p(x|\theta)$ 服从指数分布，选逆Gamma分布



§ 6.5 区间估计

点估计不能反映估计的精度, 故而本节引入了区间估计.



定义6.1 设 X_1, X_2, \dots, X_n 是来自分布函数为 $F(x; \theta)$ 的总体 X 的一个样本, θ 为未知参数, 对于给定值 α , $0 < \alpha < 1$, 若存在两个统计量

$$\hat{\theta}_L = \hat{\theta}_L(X_1, X_2, \dots, X_n), \quad \hat{\theta}_U = \hat{\theta}_U(X_1, X_2, \dots, X_n),$$

使得

$$P\{\hat{\theta}_L \leq \theta \leq \hat{\theta}_U\} = 1 - \alpha \quad (3.1)$$



则称随机区间 $[\hat{\theta}_L, \hat{\theta}_U]$ 为 θ 的置信水平为 $1-\alpha$ 的置信区间，或简称 $[\hat{\theta}_L, \hat{\theta}_U]$ 是 θ 的 $1-\alpha$ 置信区间.

$\hat{\theta}_L$ 和 $\hat{\theta}_U$ 分别称为 θ 的（双侧）置信下限 和置信上限.



注：置信水平为 $1 - \alpha$ 的置信区间的含义是：

利用样本值所构造的一个随机区间 $[\hat{\theta}_L, \hat{\theta}_U]$ 能盖住未知参数 θ 的概率为 $1 - \alpha$ 。

因为这个随机区间会随样本观察值的不同而不同，它有时盖住了参数 θ ，有时没有盖住 θ ，

因此用这种方法作区间估计时，100 次中大约有 $100(1 - \alpha)$ 个区间能盖住未知参数 θ ， 100α 个左右区间不能盖住 θ 。



例6.5.1 设 x_1, x_2, \dots, x_{10} 是来自 $N(\mu, \sigma^2)$ 的样本,

则 μ 的置信水平为 $1-\alpha$ 的置信区间为

$$\left[\bar{x} - t_{1-\alpha/2}(9) s / \sqrt{10}, \quad \bar{x} + t_{1-\alpha/2}(9) s / \sqrt{10} \right]$$

其中, \bar{x} , s 分别为样本均值和样本标准差。这个置信区间的由来将在6.5.3节中说明, 这里用它来说明置信区间的含义。

若取 $\alpha=0.10$, 则 $t_{0.95}(9)=1.8331$, 上式化

为

$$[\bar{x} - 0.5797 s, \quad \bar{x} + 0.5797 s]$$



现假定 $\mu=15, \sigma^2=4$ ，则我们可以用随机模拟方法由 $N(15,4)$ 产生一个容量为10的样本，如下即是这样一个样本：14.85 13.01 13.50
14.93 16.97


13.80 17.9533 13.37 16.29 12.38

由该样本可以算得 $\bar{x} = 14.7053, s = 1.8438$
从而得到 μ 的一个区间估计为

$$[14.7053 - 0.5797 \times 1.8438, 14.7053 + 0.5797 \times 1.8438] = [13.6427, 15.7679]$$


该区间包含 μ 的真值--15。现重复这样的方法100次，可以得到100个样本，也就得到100个区间，我们将这100个区间画在图6.5.1上。





由图6.5.1
可以看出，
这100个
区间中有
91个包含
参数真值
15，另外
9个不包
含参数真
值。

图6.5.1 μ 的置信水平为0.90的置信区间



取 $\alpha=0.50$ ，
我们也可以
给出**100**个这
样的区间，
见图6.5.2。
可以看出，
这**100**个区间
中有**50**个包
含参数真值
15，另外**50**
个不包含参
数真值。

图6.5.2 μ 的置信水平为0.50的置信区间

例6.1 设总体 $X \sim N(\mu, \sigma^2)$, σ^2 为已知, μ 为未知,

设 X_1, X_2, \dots, X_n 是来自 X 的样本, 试求 μ 的置信度为 $1 - \alpha$ 的置信区间。

解: (1) 在 σ^2 已知条件下, 求置信度为 $1 - \alpha$ 的未知参数 μ 的置信区间,

(2) μ 的点估计为 \bar{X} , 故构造含 μ 的样本函数为

$$\frac{\bar{X} - \mu}{\sigma / \sqrt{n}} \sim N(0, 1)$$



(3) $\sqrt{n} \frac{\bar{X} - \mu}{\sigma}$ 落在任一区间 $[a, b]$ 内取值的概率

都能得到, 即

$$P\left\{a \leq \sqrt{n} \frac{\bar{X} - \mu}{\sigma} \leq b\right\} = \Phi(b) - \Phi(a).$$


若令 $P\left\{a \leq \sqrt{n} \frac{\bar{X} - \mu}{\sigma} \leq b\right\} = 1 - \alpha.$

区间端点 $[a, b]$ 有无穷选择。若要使区间长度最短, 只有取关于原点对称的区间。

即 $a = -z_{\frac{\alpha}{2}} = z_{1-\frac{\alpha}{2}}, b = z_{\frac{\alpha}{2}}.$



由标准正态分布的上 α 分位点的定义知



即
$$P\left\{\bar{X} - \frac{\sigma}{\sqrt{n}} z_{\alpha/2} < \mu < \bar{X} + \frac{\sigma}{\sqrt{n}} z_{\alpha/2}\right\} = 1 - \alpha,$$



由 $\Phi(z_{\alpha/2}) = 1 - \frac{\alpha}{2}$, 查表得 $z_{\alpha/2}$ 的值;

于是得 μ 的一个置信水平为 $1 - \alpha$ 的置信区间

$$\left(\bar{X} - \frac{\sigma}{\sqrt{n}} z_{\alpha/2}, \bar{X} + \frac{\sigma}{\sqrt{n}} z_{\alpha/2} \right).$$

这样的置信区间常写成 $\left(\bar{X} \pm \frac{\sigma}{\sqrt{n}} z_{\alpha/2} \right).$

其置信区间的长度为

$$2 \times \frac{\sigma}{\sqrt{n}} z_{\alpha/2}.$$



注意：置信水平为 $1 - \alpha$ 的置信区间是不唯一的

如果在本例中取 $n = 16, \sigma = 1, \alpha = 0.05,$

查表可得 $z_{\alpha/2} = z_{0.025} = 1.96,$

得一个置信水平为 **0.95** 的置信区间 $\left(\bar{X} \pm \frac{1}{\sqrt{16}} \times 1.96 \right).$

由一个样本值算得样本均值的观察值 $\bar{x} = 5.20,$

则置信区间为 $(5.20 \pm 0.49),$ 即 $(4.71, 5.69).$



就是说估计总体的均值在**4.71**与**5.69**之间, 这个估计的可信程度为**95%**.


若依此区间内任一值作为 μ 的近似值 ,

其误差不大于 $\left(\frac{1}{\sqrt{16}} \times 1.96 \times 2 \right) = 0.98$


这个误差的可信度为**95%**.



取 $\alpha = 0.05$



$$\begin{aligned} Z_{\frac{\alpha}{2}} - Z_{1-\frac{\alpha}{2}} &= 1.96 - (-1.96) \\ &= 3.92 \end{aligned}$$



$$\begin{aligned} Z_{\frac{2\alpha}{3}} - Z_{1-\frac{\alpha}{3}} &= 1.84 - (-2.13) \\ &= 3.97 \end{aligned}$$



说明: 对于概率密度的图形是单峰且关于纵坐标轴对称的情况, 易证取 a 和 b 关于原点对称时, 能使置信区间长度最小.



6.5.2 枢轴量法

构造未知参数 θ 的置信区间的最常用的方法是枢轴量法，其步骤可以概括为如下三步：

1. 设法构造一个样本和 θ 的函数 $G=G(x_1, x_2, \dots, x_n, \theta)$ 使得 G 的分布不依赖于未知参数。一般称具有这种性质的 G 为枢轴量。

2. 适当地选择两个常数 c, d ，使对给定的 α ($0 < \alpha < 1$) 有

$$P(c \leq G \leq d) = 1 - \alpha$$

3. 假如能将 $c \leq G \leq d$ 进行不等式等价变形化为

$$\hat{\theta}_L \leq \theta \leq \hat{\theta}_U$$

则 $[\hat{\theta}_L, \hat{\theta}_U]$ 是 θ 的 $1-\alpha$ 同等置信区间。



关于置信区间的构造有两点说明：

- 满足置信度要求的 c 与 d 通常不唯一。若有可能，应选平均长度 $E(\hat{\theta}_U - \hat{\theta}_L)$ 达到最短的 c 与 d ，这在 G 的分布为对称分布场合通常容易实现。
- 实际中，选平均长度 $E(\hat{\theta}_U - \hat{\theta}_L)$ 尽可能短的 c 与 d ，这往往很难实现，因此，常这样选择 c 与 d ，使得两个尾部概率各为 $\alpha/2$ ，即 $P(G < c) = P(G > d) = \alpha/2$ ，这样的置信区间称为等尾置信区间。这是在 G 的分布为偏态分布场合常采用的方法。



6.6.3 单个正态总体参数的 区间估计

设给定置信水平为 $1 - \alpha$, 并设 X_1, X_2, \dots, X_n 为总体 $N(\mu, \sigma^2)$ 的样本, \bar{X}, S^2 分别是样本均值和样本方差.

1. 均值 μ 的置信区间

(1) σ^2 为已知, 由上节例6可知:

μ 的一个置信水平为 $1 - \alpha$ 的置信区间 $\left(\bar{X} \pm \frac{\sigma}{\sqrt{n}} z_{\alpha/2} \right)$.



例6.2 包糖机某日开工包了12包糖, 称得质量(单位:克)分别为506, 500, 495, 488, 504, 486, 505, 513, 521, 520, 512, 485. 假设重量服从正态分布, 且标准差为 $\sigma = 10$, 试求糖包的平均质量 μ 的 $1 - \alpha$ 置信区间 (分别取 $\alpha = 0.10$ 和 $\alpha = 0.05$).

解 $\sigma = 10, \quad n = 12,$

计算得 $\bar{x} = 502.92,$

(1) 当 $\alpha = 0.10$ 时, $1 - \frac{\alpha}{2} = 0.95,$

查表得 $z_{\alpha/2} = z_{0.05} = 1.645,$



$$\bar{x} - \frac{\sigma}{\sqrt{n}} z_{\alpha/2} = 502.92 - \frac{10}{\sqrt{12}} \times 1.645 = 498.17,$$

$$\bar{x} + \frac{\sigma}{\sqrt{n}} z_{\alpha/2} = 502.92 + \frac{10}{\sqrt{12}} \times 1.645 = 507.67,$$

即 μ 的置信度为 90% 的置信区间为

(498.17, 507.67).

(2) 当 $\alpha = 0.05$ 时, $1 - \frac{\alpha}{2} = 0.975,$



查表得

$$z_{\alpha/2} = z_{0.025} = 1.96,$$

同理可得 μ 的置信度为 95% 的置信区间为

$$(497.26, 508.58).$$

从此例可以看出

当置信度 $1 - \alpha$ 较大时, 置信区间也较大,

当置信度 $1 - \alpha$ 较小时, 置信区间也较小.



(2) σ^2 为未知,

μ 的置信度为 $1-\alpha$ 的置信区间 $\left(\bar{X} \pm \frac{S}{\sqrt{n}} t_{\alpha/2}(n-1) \right)$.

推导过程如下:

由于区间 $\left(\bar{X} \pm \frac{\sigma}{\sqrt{n}} z_{\alpha/2} \right)$ 中含有未知参数 σ , 不能直接使用此区间 ,

但因为 S^2 是 σ^2 的无偏估计 , 可用 $S = \sqrt{S^2}$ 替换 σ ,



又根据第四章定理 4.5.1(4) 知 $\frac{\bar{X} - \mu}{S / \sqrt{n}} \sim t(n - 1),$

$$\text{则 } P\left\{-t_{\alpha/2}(n-1) < \frac{\bar{X} - \mu}{S / \sqrt{n}} < t_{\alpha/2}(n-1)\right\} = 1 - \alpha,$$

$$\text{即 } P\left\{\bar{X} - \frac{S}{\sqrt{n}}t_{\alpha/2}(n-1) < \mu < \bar{X} + \frac{S}{\sqrt{n}}t_{\alpha/2}(n-1)\right\} = 1 - \alpha,$$

于是得 μ 的置信度为 $1-\alpha$ 的置信区间

$$\left(\bar{X} \pm \frac{S}{\sqrt{n}}t_{\alpha/2}(n-1)\right).$$



例6.3 (续例6.2) 如果只假设糖包的重量服从正态分布

$N(\mu, \sigma^2)$, 试求糖包重量 μ 的 95% 的置信区间 .

解 此时 σ 未知, $n = 12$,

$\alpha = 0.05$, $\bar{x} = 502.92$, $s = 12.35$,

查 $t(n-1)$ 分布表可知 : $t_{0.025}(11) = 2.201$,

于是 $\frac{s}{\sqrt{n}} t_{\alpha/2}(n-1) = \frac{12.35}{\sqrt{12}} \times 2.201 = 7.85$,

得 μ 的置信度为 95% 的置信区间 $(495.07, 510.77)$.



2. 方差 σ^2 的置信区间

方差 σ^2 的置信度为 $1-\alpha$ 的置信区间

$$\left(\frac{(n-1)S^2}{\chi_{\alpha/2}^2(n-1)}, \frac{(n-1)S^2}{\chi_{1-\alpha/2}^2(n-1)} \right).$$

推导过程如下：

因为 S^2 是 σ^2 的无偏估计，

根据第四章定理4.5.1知

$$\frac{(n-1)S^2}{\sigma^2} \sim \chi^2(n-1),$$



则
$$P\left\{\chi_{1-\alpha/2}^2(n-1) < \frac{(n-1)S^2}{\sigma^2} < \chi_{\alpha/2}^2(n-1)\right\} = 1 - \alpha,$$

即
$$P\left\{\frac{(n-1)S^2}{\chi_{\alpha/2}^2(n-1)} < \sigma^2 < \frac{(n-1)S^2}{\chi_{1-\alpha/2}^2(n-1)}\right\} = 1 - \alpha,$$

于是得方差 σ^2 的置信度为 $1 - \alpha$ 的置信区间

$$\left(\frac{(n-1)S^2}{\chi_{\alpha/2}^2(n-1)}, \frac{(n-1)S^2}{\chi_{1-\alpha/2}^2(n-1)} \right).$$




进一步可得:

标准差 σ 的一个置信度为 $1-\alpha$ 的置信区间

$$\left(\frac{\sqrt{n-1}S}{\sqrt{\chi_{\alpha/2}^2(n-1)}}, \frac{\sqrt{n-1}S}{\sqrt{\chi_{1-\alpha/2}^2(n-1)}} \right).$$

注意: 在密度函数不对称时,
如 χ^2 分布和 F 分布,
习惯上仍取对称的分位点来
确定置信区间(如图).



例6.4 (续例6.1) 求例 1中总体方差 σ^2 和标准差 σ 的

置信度为 0.95 的置信区间 .

解 $\frac{\alpha}{2} = 0.025, \quad 1 - \frac{\alpha}{2} = 0.975, \quad n - 1 = 11,$

查 $\chi^2(n-1)$ 分布表可知 :

$$\chi_{0.025}^2(11) = 21.920, \quad \chi_{0.975}^2(11) = 3.816,$$


方差 σ^2 的置信区间 $(78.97, 453.64);$

标准差 σ 的置信区间 $(8.87, 21.30).$



表3.1单个正态总体参数的区间估计一览表

被估计参数	条件	估计统计量	服从分布	置信度为1-α的置信区间	α的分位数
μ	σ 已知	$U = \frac{\bar{X} - \mu}{\sigma/\sqrt{n}}$	$N(0,1)$	$(\bar{X} \pm \frac{\sigma}{\sqrt{n}} u_{\alpha/2})$	$\Phi(u_{\alpha/2}) = 1 - \alpha/2$
μ	σ 未知	$T = \frac{\bar{X} - \mu}{S/\sqrt{n}}$	$t(n-1)$	$(\bar{X} \pm \frac{S}{\sqrt{n}} t_{\alpha/2}(n-1))$	$P\{T > t_{\alpha/2}(n-1)\} = \alpha/2$
σ^2	μ 已知	$\chi^2 = \frac{\sum_{i=1}^n (X_i - \mu)^2}{\sigma^2}$	$\chi^2(n)$	$(\frac{\sum_{i=1}^n (X_i - \mu)^2}{\chi_{\alpha/2}^2(n)}, \frac{\sum_{i=1}^n (X_i - \mu)^2}{\chi_{1-\alpha/2}^2(n)})$	$P\{\chi^2 > \chi_{\alpha/2}^2(n)\} = \alpha/2$ $P\{\chi^2 > \chi_{1-\alpha/2}^2(n)\} = \alpha/2$
σ^2	μ 未知	$\chi^2 = \frac{(n-1)S^2}{\sigma^2}$	$\chi^2(n-1)$	$(\frac{(n-1)S^2}{\chi_{\alpha/2}^2(n-1)}, \frac{(n-1)S^2}{\chi_{1-\alpha/2}^2(n-1)})$	$P\{\chi^2 > \chi_{\alpha/2}^2(n-1)\} = \alpha/2$ $P\{\chi^2 > \chi_{1-\alpha/2}^2(n-1)\} = \alpha/2$
σ	μ 未知	$\chi^2 = \frac{(n-1)S^2}{\sigma^2}$	$\chi^2(n-1)$	$(\sqrt{\frac{(n-1)S^2}{\chi_{\alpha/2}^2(n-1)}}, \sqrt{\frac{(n-1)S^2}{\chi_{1-\alpha/2}^2(n-1)}})$	$P\{\chi^2 > \chi_{\alpha/2}^2(n-1)\} = \alpha/2$ $P\{\chi^2 > \chi_{1-\alpha/2}^2(n-1)\} = \alpha/2$



例3.3 从一台机床加工的轴承中,随机地抽取 200 件,测得其椭圆度,得样本观察值 $\bar{X} = 0.081$ 毫米,并由累积资料知椭圆度 X 服从 $N(\mu, 0.025^2)$, 试在置信度 0.95 下, 求 μ 的置信区间的相应于样本观察值的一个现实区间。

解:由一览表中查得, σ^2 已知条件下, μ 置信度为 $1 - \alpha = 0.95$ 的置信区间为

$$(\bar{X} \pm \frac{\sigma}{\sqrt{n}} z_{\alpha/2})$$

其中 $z_{\alpha/2} = z_{\frac{0.05}{2}} = 1.96$, 且已知 $\sigma = 0.025$, $n = 200$, $\bar{x} = 0.081$

故所求现实区间为

$$(0.081 \pm \frac{0.025}{\sqrt{200}} \times 1.96) = (0.081 \pm 0.035) = (0.0775, 0.0845)$$



例3.4 已知某种白帜灯泡的寿命 $X \sim N(\mu, \sigma^2)$, 在一批该种灯泡中随机地抽取 10 只, 测得其寿命 (以小时计算) 于下 :

1067 919 1196 785 1126 936 918 1156 920 948

试求未知参数 μ, σ^2 及 σ 的知心度为 0.95 的置信区间。

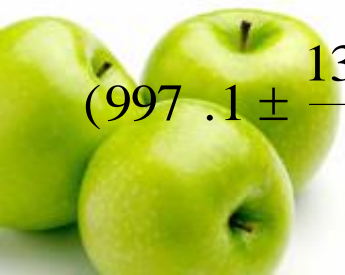
解 : (1) 查一览表中查得 σ^2 未知条件下, μ 的置信度为 $1 - \alpha = 0.95$ 的置信区间为 :

$$(\bar{X} \pm \frac{S}{\sqrt{n}} t_{\alpha/2}(n-1))$$

查 t 分布表得 $t_{\alpha/2}(n-1) = t_{0.05/2}(10-1) = 2.2622$

由数据计算得 $\bar{x} = 997.1, s = 131.5476$

故得 μ 的置信度为 0.95 的置信区间为


$$(997.1 \pm \frac{131.5476}{\sqrt{10}} \times 2.2622) = (997.1 \pm 94.1) = (903, 1091.2)$$

(2)由一览表查得 : μ 未知条件下 , σ^2 的置信度为 $1 - \alpha = 0.95$ 的置信区间为

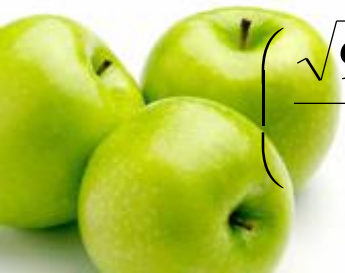
$$\left(\frac{(n-1)S^2}{x_{\alpha/2}^2(n-1)}, \frac{(n-1)S^2}{x_{1-\alpha/2}^2(n-1)} \right)$$

查 χ^2 分布表得 $x_{\alpha/2}^2(n-1) = x_{0.05/2}^2(9) = 2.7$

故得 σ^2 置信区间为 0.95 的置信区间为

$$\left(\frac{9 \times 131.5476}{19.023}, \frac{9 \times 131.5476}{2.7} \right) = (8187.1, 57682.6)$$

σ 的置信度为 0.95 的置信区间为


$$\left(\frac{\sqrt{9} \times 131.5476}{\sqrt{19.023}}, \frac{\sqrt{9} \times 131.5476}{\sqrt{2.7}} \right) = (90.5, 240.2)$$

设单个总体 $X \sim N(\mu, \sigma^2)$,

1. 单个总体均值 μ 的置信区间

$$\left\{ \begin{array}{l} (1) \sigma^2 \text{ 为已知, } \left(\bar{X} \pm \frac{\sigma}{\sqrt{n}} z_{\alpha/2} \right). \\ (2) \sigma^2 \text{ 为未知, } \left(\bar{X} \pm \frac{S}{\sqrt{n}} t_{\alpha/2}(n-1) \right). \end{array} \right.$$

2. 单个总体方差 σ^2 的置信区间

$$\left(\frac{(n-1)S^2}{\chi_{\alpha/2}^2(n-1)}, \frac{(n-1)S^2}{\chi_{1-\alpha/2}^2(n-1)} \right).$$



二、两个总体 $N(\mu_1, \sigma_1^2)$, $N(\mu_2, \sigma_2^2)$ 的情况

设给定置信度为 $1 - \alpha$, 并设 X_1, X_2, \dots, X_n 为第一个总体 $N(\mu_1, \sigma_1^2)$ 的样本, Y_1, Y_2, \dots, Y_n 为第二个总体 $N(\mu_2, \sigma_2^2)$ 的样本, \bar{X}, \bar{Y} 分别是第一、二个总体的样本均值, S_1^2, S_2^2 分别是第一、二个总体的样本方差.

讨论两个整体总体均值差和方差比的估计问题.



1. 两个总体均值差 $\mu_1 - \mu_2$ 的置信区间

(1) σ_1^2 和 σ_2^2 均为已知

$\mu_1 - \mu_2$ 的一个置信度为 $1-\alpha$ 的置信区间

$$\left(\bar{X} - \bar{Y} \pm z_{\alpha/2} \sqrt{\frac{\sigma_1^2}{n_1} + \frac{\sigma_2^2}{n_2}} \right).$$

推导过程如下:

因为 \bar{X} , \bar{Y} 分别是 μ_1, μ_2 的无偏估计 ,

所以 $\bar{X} - \bar{Y}$ 是 $\mu_1 - \mu_2$ 的无偏估计 ,



由 \bar{X} , \bar{Y} 的独立性及

$$\bar{X} \sim N\left(\mu_1, \frac{\sigma_1^2}{n_1}\right), \quad \bar{Y} \sim N\left(\mu_2, \frac{\sigma_2^2}{n_2}\right),$$

可知 $\bar{X} - \bar{Y} \sim N\left(\mu_1 - \mu_2, \frac{\sigma_1^2}{n_1} + \frac{\sigma_2^2}{n_2}\right),$

或 $\frac{(\bar{X} - \bar{Y}) - (\mu_1 - \mu_2)}{\sqrt{\frac{\sigma_1^2}{n_1} + \frac{\sigma_2^2}{n_2}}} \sim N(0, 1),$



于是得 $\mu_1 - \mu_2$ 的一个置信度为 $1 - \alpha$ 的置信区间

$$\left(\bar{X} - \bar{Y} \pm z_{\alpha/2} \sqrt{\frac{\sigma_1^2}{n_1} + \frac{\sigma_2^2}{n_2}} \right).$$

(2) σ_1^2 和 σ_2^2 均为未知 ,

只要 n_1 和 n_2 都很大 (实用上 > 50 即可), 则有

$\mu_1 - \mu_2$ 的一个置信度为 $1 - \alpha$ 的近似置信区间

$$\left(\bar{X} - \bar{Y} \pm z_{\alpha/2} \sqrt{\frac{S_1^2}{n_1} + \frac{S_2^2}{n_2}} \right).$$



(3) $\sigma_1^2 = \sigma_2^2 = \sigma^2$, 但 σ^2 为未知 ,



$\mu_1 - \mu_2$ 的一个置信度为 $1 - \alpha$ 的置信区间

$$\left(\bar{X} - \bar{Y} \pm t_{\alpha/2}(n_1 + n_2 - 2) S_w \sqrt{\frac{1}{n_1} + \frac{1}{n_2}} \right).$$

$$\text{其中 } S_w^2 = \frac{(n_1 - 1)S_1^2 + (n_2 - 1)S_2^2}{n_1 + n_2 - 2}, \quad S_w = \sqrt{S_w^2}.$$



例7 为比较I, II两种型号步枪子弹的枪口速度, 随机地取I型子弹10发, 得到枪口速度的平均值为 $\bar{x}_1 = 500$ (m / s), 标准差 $s_1 = 1.10$ (m / s), 随机地取II型子弹20发, 得枪口速度平均值为 $\bar{x}_2 = 496$ (m / s), 标准差 $s_2 = 1.20$ (m / s), 假设两总体都可认为近似地服从正态分布, 且由生产过程可认为它们的方差相等, 求两总体均值差 $\mu_1 - \mu_2$ 的置信度为0.95的置信区间.

解 由题意, 两总体样本独立且方差相等(但未知),



$$\frac{\alpha}{2} = 0.025, \quad n_1 = 10, \quad n_2 = 20, \quad n_1 + n_2 - 2 = 28,$$

查 $t(n-1)$ 分布表可知 : $t_{0.025}(28) = 2.0484$,

$$s_w^2 = \frac{9 \times 1.10^2 + 19 \times 1.20^2}{28}, \quad s_w = \sqrt{s_w^2} = 1.1688 ,$$

于是得 $\mu_1 - \mu_2$ 的一个置信度为 0.95 的置信区间

$$\left(\bar{x}_1 - \bar{x}_2 \pm S_w \times t_{0.025}(28) \sqrt{\frac{1}{10} + \frac{1}{20}} \right) = (4 \pm 0.93) ,$$

即所求置信区间为 $(3.07, 4.93)$.



例8 为提高某一化学生产过程的得率, 试图采用一种新的催化剂, 为慎重起见, 在试验工厂先进行试验. 设采用原来的催化剂进行了 $n_1 = 8$ 次试验, 得到得率的平均值 $\bar{x}_1 = 91.73$. 样本方差 $s_1^2 = 3.89$, 又采用新的催化剂进行了 $n_2 = 8$ 次试验, 得到得率的平均值 $\bar{x}_2 = 93.75$, 样本方差 $s_2^2 = 4.02$, 假设两总体都可认为近似地服从正态分布, 且方差相等, 求两总体均值差 $\mu_1 - \mu_2$ 的置信水平为0.95的置信区间.

解 由题意, 两总体样本独立且方差相等(但未知),



$$\text{且 } s_w^2 = \frac{(n_1 - 1)S_1^2 + (n_2 - 1)S_2^2}{n_1 + n_2 - 2} = 3.96,$$

于是得 $\mu_1 - \mu_2$ 的一个置信水平为 0.95 的置信区间

$$\left(\bar{x}_1 - \bar{x}_2 \pm s_w \times t_{0.025}(14) \sqrt{\frac{1}{8} + \frac{1}{8}} \right) = (-2.02 \pm 2.13),$$

即所求置信区间为 $(-4.15, 0.11)$.



2. 两个总体方差比 $\frac{\sigma_1^2}{\sigma_2^2}$ 的置信区间

仅讨论总体均值 μ_1, μ_2 为未知的情况.

$\frac{\sigma_1^2}{\sigma_2^2}$ 的一个置信度为 $1-\alpha$ 的置信区间

$$\left(\frac{S_1^2}{S_2^2} \frac{1}{F_{\alpha/2}(n_1-1, n_2-1)}, \frac{S_1^2}{S_2^2} \frac{1}{F_{1-\alpha/2}(n_1-1, n_2-1)} \right).$$

推导过程如下:

由于 $\frac{(n_1-1)S_1^2}{\sigma_1^2} \sim \chi^2(n_1-1), \frac{(n_2-1)S_2^2}{\sigma_2^2} \sim \chi^2(n_2-1),$



且由假设知 $\frac{(n_1 - 1)S_1^2}{\sigma_1^2}$ 与 $\frac{(n_2 - 1)S_2^2}{\sigma_2^2}$ 相互独立 ,

根据F分布的定义, 知 $\frac{S_1^2 / \sigma_1^2}{S_2^2 / \sigma_2^2} \sim F(n_1 - 1, n_2 - 1),$

$$\text{即 } \frac{S_1^2 / \sigma_1^2}{S_2^2 / \sigma_2^2} = \frac{\frac{(n_1 - 1)S_1^2}{\sigma_1^2} / (n_1 - 1)}{\frac{(n_2 - 1)S_2^2}{\sigma_2^2} / (n_2 - 1)} \sim F(n_1 - 1, n_2 - 1),$$



$$P\left\{F_{1-\alpha/2}(n_1-1, n_2-1) < \frac{S_1^2/\sigma_1^2}{S_2^2/\sigma_2^2} < F_{\alpha/2}(n_1-1, n_2-1)\right\}$$

$$= 1 - \alpha,$$

$$P\left\{\frac{S_1^2}{S_2^2} \frac{1}{F_{\alpha/2}(n_1-1, n_2-1)} < \frac{\sigma_1^2}{\sigma_2^2} < \frac{S_1^2}{S_2^2} \frac{1}{F_{1-\alpha/2}(n_1-1, n_2-1)}\right\}$$

$$= 1 - \alpha,$$

于是得 $\frac{\sigma_1^2}{\sigma_2^2}$ 的一个置信度为 $1 - \alpha$ 的置信区间

$$\left(\frac{S_1^2}{S_2^2} \frac{1}{F_{\alpha/2}(n_1-1, n_2-1)}, \frac{S_1^2}{S_2^2} \frac{1}{F_{1-\alpha/2}(n_1-1, n_2-1)} \right).$$



例9 研究由机器 **A** 和机器 **B** 生产的钢管内径, 随机抽取机器 **A** 生产的管子 **18** 只, 测得样本方差为 $s_1^2 = 0.34 (\text{mm}^2)$; 抽取机器 **B** 生产的管子 **13** 只, 测得样本方差为 $s_2^2 = 0.29 (\text{mm}^2)$. 设两样本相互独立, 且设由机器 **A** 和机器 **B** 生产的钢管内径分别服从正态分布 $N(\mu_1, \sigma_1^2)$, $N(\mu_2, \sigma_2^2)$, $\mu_i, \sigma_i^2 (i = 1, 2)$ 均未知, 求方差比 σ_1^2 / σ_2^2 的置信度为 **0.90** 的置信区间.

解 $n_1 = 18, \quad n_2 = 13, \quad \alpha = 0.10,$
 $s_1^2 = 0.34 (\text{mm}^2), \quad s_2^2 = 0.29 (\text{mm}^2),$



$$F_{\alpha/2}(n_1 - 1, n_2 - 1) = F_{0.05}(17, 12) = 2.59,$$

$$F_{1-\alpha/2}(17, 12) = F_{0.95}(17, 12) = \frac{1}{F_{0.05}(12, 17)} = \frac{1}{2.38},$$

于是得 $\frac{\sigma_1^2}{\sigma_2^2}$ 的一个置信度为0.90的置信区间

$$\left(\frac{0.34}{0.29} \times \frac{1}{2.59}, \frac{0.34}{0.29} \times 2.38 \right) = (0.45, 2.79).$$



例10 甲、乙两台机床加工同一种零件, 在机床甲加工的零件中抽取9个样品, 在机床乙加工的零件中抽取6个样品, 并分别测得它们的长度(单位:mm), 由所给数据算得 $s_1^2 = 0.245$, $s_2^2 = 0.357$, 在置信度 0.98 下, 试求这两台机床加工精度之比 σ_1/σ_2 的置信区间. 假定测量值都服从正态分布, 方差分别为 σ_1^2, σ_2^2 .

解 $n_1 = 9$, $n_2 = 6$, $\alpha = 0.02$,

$$F_{1-\alpha/2}(n_1-1, n_2-1) = F_{0.99}(8, 5) = 10.3,$$



$$F_{\alpha/2}(8, 5) = F_{0.01}(8, 5) = \frac{1}{F_{0.99}(5, 8)} = \frac{1}{6.63},$$

于是得 $\frac{\sigma_1}{\sigma_2}$ 的一个置信度为 0.98 的置信区间

$$\left(\sqrt{\frac{S_1^2}{S_2^2} \frac{1}{F_{\alpha/2}(n_1-1, n_2-1)}}, \sqrt{\frac{S_1^2}{S_2^2} \frac{1}{F_{1-\alpha/2}(n_1-1, n_2-1)}} \right)$$

$$= \left(\sqrt{\frac{0.245}{0.357 \times 10.3}}, \sqrt{\frac{0.245 \times 6.63}{0.357}} \right) = (0.258, 2.133).$$



第六节 $(0-1)$ 分布参数的区间估计

一、置信区间公式

二、典型例题



在样本容量充分大时，可以用渐近分布来构造近似的置信区间。一个典型的例子是关于比例 p 的置信区间。



一、置信区间公式

设有一容量 $n > 50$ 的大样本，它来自 $(0-1)$ 分布的总体 X ， X 的分布律为 $f(x; p) = p^x (1-p)^{1-x}$ ， $x = 0, 1$ ，其中 p 为未知参数，则 p 的置信度为 $1-\alpha$ 的置信区间是

$$\left(\frac{-b - \sqrt{b^2 - 4ac}}{2a}, \frac{-b + \sqrt{b^2 - 4ac}}{2a} \right),$$

其中 $a = n + z_{\alpha/2}^2$ ， $b = -(2n\bar{X} + z_{\alpha/2}^2)$ ， $c = n\bar{X}^2$ 。



推导过程如下:

因为(0-1)分布的均值和方差分别为

$$\mu = p, \quad \sigma^2 = p(1-p),$$

设 X_1, X_2, \dots, X_n 是一个样本, 因为容量 n 较大,

由**中心极限定理**知
$$\frac{\sum_{i=1}^n X_i - np}{\sqrt{np(1-p)}} = \frac{n\bar{X} - np}{\sqrt{np(1-p)}}$$

近似地服从 $N(0,1)$ 分布,

$$P\left\{-z_{\alpha/2} < \frac{n\bar{X} - np}{\sqrt{np(1-p)}} < z_{\alpha/2}\right\} \approx 1 - \alpha,$$



不等式 $-z_{\alpha/2} < \frac{n\bar{X} - np}{\sqrt{np(1-p)}} < z_{\alpha/2}$

等价于 $(n + z_{\alpha/2}^2)p^2 - (2n\bar{X} + z_{\alpha/2}^2)p + n\bar{X}^2 < 0$,

令 $p_1 = \frac{-b - \sqrt{b^2 - 4ac}}{2a}$, $p_2 = \frac{-b + \sqrt{b^2 - 4ac}}{2a}$,

其中 $a = n + z_{\alpha/2}^2$, $b = -(2n\bar{X} + z_{\alpha/2}^2)$, $c = n\bar{X}^2$.

则 p 的近似置信水平为 $1 - \alpha$ 的置信区间是

(p_1, p_2) .



二、典型例题

例1 设从一大批产品的100个样品中, 得一级品60个, 求这批产品的一级品率 p 的置信水平为0.95的置信区间.

解 一级品率 p 是(0-1)分布的参数,

$$n = 100, \quad \bar{x} = \frac{60}{100} = 0.6,$$

$$1 - \alpha = 0.95, \quad z_{\alpha/2} = z_{0.025} = 1.96,$$

$$\text{则 } a = n + z_{\alpha/2}^2 = 103.84,$$



$$b = -(2n\bar{X} + z_{\alpha/2}^2) = -(2n\bar{x} + z_{\alpha/2}^2) = -123.84,$$

$$c = n\bar{X}^2 = n\bar{x}^2 = 36,$$

$$\text{于是 } p_1 = \frac{-b - \sqrt{b^2 - 4ac}}{2a} = 0.50,$$

$$p_2 = \frac{-b + \sqrt{b^2 - 4ac}}{2a} = 0.69,$$

p 的置信水平为0.95的置信区间为 (0.50, 0.69).



例2 设从一大批产品的120个样品中, 得次品9个, 求这批产品的次品率 p 的置信水平为0.90的置信区间.

解 $n = 120$, $\bar{x} = \frac{9}{120} = 0.075$, $1 - \alpha = 0.90$,

则 $a = n + z_{\alpha/2}^2 = 120.71$,

$$b = -(2n\bar{x} + z_{\alpha/2}^2) = -(2 \times 120 \times 0.075 + 1.645^2) = -24.31,$$

$$c = -n\bar{x}^2 = -120 \times 0.075^2 = -0.972,$$



于是 $p_1 = \frac{-b - \sqrt{b^2 - 4ac}}{2a} = 0.056,$

$$p_2 = \frac{-b + \sqrt{b^2 - 4ac}}{2a} = 0.143,$$

p 的置信水平为0.90的置信区间为 (0.056, 0.143).

通常，未知参数 p 的置信度为 $1 - \alpha$ 的置信区间近似为

$$\bar{X} \pm z_{\alpha/2} \sqrt{\bar{X}(1 - \bar{X})/n}$$



第七节 单侧置信区间

一、问题的引入

二、基本概念

三、典型例题

四、小结



一、问题的引入

在以上各节的讨论中, 对于未知参数 θ , 我们给出两个统计量 $\underline{\theta}, \bar{\theta}$, 得到 θ 的双侧置信区间 $(\underline{\theta}, \bar{\theta})$.

但在某些实际问题中, 例如, 对于设备、元件的寿命来说, 平均寿命长是我们希望的, 我们关心的是平均寿命 θ 的“下限”; 与之相反, 在考虑产品的废品率 p 时, 我们常关心参数 p 的“上限”, 这就引出了单侧置信区间的概念.



二、基本概念

1. 单侧置信区间的定义



对于给定值 α ($0 < \alpha < 1$), 若由样本 X_1, X_2, \dots, X_n 确定的统计量 $\underline{\theta} = \underline{\theta}(X_1, X_2, \dots, X_n)$, 对于任意 $\theta \in \Theta$ 满足

$$P\{\theta > \underline{\theta}\} \geq 1 - \alpha,$$

则称随机区间 $(\underline{\theta}, +\infty)$ 是 θ 的置信水平为 $1 - \alpha$ 的单侧置信区间, $\underline{\theta}$ 称为 θ 的置信水平为 $1 - \alpha$ 的单侧置信下限.



又如果统计量 $\bar{\theta} = \bar{\theta}(X_1, X_2, \dots, X_n)$, 对于任意 $\theta \in \Theta$ 满足

$$P\{\theta < \bar{\theta}\} \geq 1 - \alpha,$$

则称随机区间 $(-\infty, \bar{\theta})$ 是 θ 的置信水平为 $1 - \alpha$ 的单侧置信区间, $\bar{\theta}$ 称为 θ 的置信水平为 $1 - \alpha$ 的单侧置信上限.



2. 正态总体均值与方差的单侧置信区间

设正态总体 X 的均值是 μ , 方差是 σ^2 (均为未知),

X_1, X_2, \dots, X_n 是一个样本, 由 $\frac{\bar{X} - \mu}{S / \sqrt{n}} \sim t(n-1)$,

$$\text{有 } P\left\{\frac{\bar{X} - \mu}{S / \sqrt{n}} < t_{\alpha}(n-1)\right\} = 1 - \alpha,$$

$$\text{即 } P\left\{\mu > \bar{X} - \frac{S}{\sqrt{n}} t_{\alpha}(n-1)\right\} = 1 - \alpha,$$



于是得 μ 的一个置信水平为 $1 - \alpha$ 的单侧置信区间

$$\left(\bar{X} - \frac{S}{\sqrt{n}} t_{\alpha}(n-1), +\infty \right),$$

μ 的置信水平为 $1 - \alpha$ 的置信下限 $\underline{\mu} = \bar{X} - \frac{S}{\sqrt{n}} t_{\alpha}(n-1).$

又根据 $\frac{(n-1)S^2}{\sigma^2} \sim \chi^2(n-1),$

有 $P \left\{ \frac{(n-1)S^2}{\sigma^2} > \chi_{1-\alpha}^2(n-1) \right\} = 1 - \alpha,$



$$\text{即 } P\left\{\sigma^2 < \frac{(n-1)S^2}{\chi_{1-\alpha}^2(n-1)}\right\} = 1 - \alpha,$$

于是得 σ^2 的一个置信水平为 $1-\alpha$ 的单侧置信区间

$$\left(0, \frac{(n-1)S^2}{\chi_{1-\alpha}^2(n-1)}\right),$$

σ^2 的置信水平为 $1-\alpha$ 的单侧置信上限

$$\overline{\sigma^2} = \frac{(n-1)S^2}{\chi_{1-\alpha}^2(n-1)}.$$



三、典型例题

例1 设从一批灯泡中, 随机地取5只作寿命试验, 测得寿命(以小时计)为 1050, 1100, 1120, 1250, 1280, 设灯泡寿命服从正态分布, 求灯泡寿命平均值的置信水平为 0.95 的单侧置信下限.

解 $1 - \alpha = 0.95$, $n = 5$, $\bar{x} = 1160$, $s^2 = 9950$,

$$t_{\alpha}(n-1) = t_{0.05}(4) = 2.1318,$$

μ 的置信水平为 0.95 的置信下限

$$\underline{\mu} = \bar{x} - \frac{s}{\sqrt{n}} t_{\alpha}(n-1) = 1065.$$



例2 设总体 X 在 $[0, \theta]$ 上服从均匀分布, 其中 θ ($\theta > 0$) 未知, (X_1, X_2, \dots, X_n) 是来自总体 X 的样本, 给定 α , 求 θ 的置信水平为 $1 - \alpha$ 的置信下限和置信上限.

解 令 $X_h = \max \{X_1, X_2, \dots, X_n\}$,

对于给定的 α , 找 $0 < \underline{\theta} \leq 1$, 使 $P\left\{\theta > \frac{X_h}{\underline{\theta}}\right\} = 1 - \alpha$,

即 $1 - \alpha = \int_0^{\underline{\theta}} n z^{n-1} dz = \underline{\theta}^n$, 于是 $\underline{\theta} = \sqrt[n]{1 - \alpha}$,

所以 $P\left\{\frac{X_h}{\sqrt[n]{1 - \alpha}} < \theta\right\} = 1 - \alpha$,



θ 的置信水平为 $1 - \alpha$ 的置信下限 $\underline{\theta} = \frac{X_h}{\sqrt[n]{1 - \alpha}}$.

对于给定的 α , 找 $0 < \bar{\theta} < 1$, 使 $P\left\{\theta < \frac{X_h}{\bar{\theta}}\right\} = 1 - \alpha$,

即 $1 - \alpha = \int_{\bar{\theta}}^1 n z^{n-1} dz = 1 - \bar{\theta}^n$, 于是 $\bar{\theta} = \sqrt[n]{\alpha}$,

所以 $P\left\{\theta < \frac{X_h}{\sqrt[n]{\alpha}}\right\} = 1 - \alpha$,

θ 的置信水平为 $1 - \alpha$ 的置信上限 $\bar{\theta} = \frac{X_h}{\sqrt[n]{\alpha}}$.



四、小结

正态总体均值 μ 的置信水平为 $1-\alpha$ 的单侧置信区间

$$\left(-\infty, \bar{X} + \frac{S}{\sqrt{n}} t_{\alpha}(n-1) \right), \quad \left(\bar{X} - \frac{S}{\sqrt{n}} t_{\alpha}(n-1), +\infty \right),$$

单侧置信上限 $\bar{\mu}$

单侧置信下限 $\underline{\mu}$

正态总体方差 σ^2 的置信水平为 $1-\alpha$ 的单侧置信区间

$$\left(0, \frac{(n-1)S^2}{\chi_{1-\alpha}^2(n-1)} \right).$$

单侧置信上限 $\overline{\sigma^2}$





第四节 样本容量的确定

(一)确定样本容量的意义

(二)估计均值时的样本容量

(三)估计比率时的样本容量




一、确定样本容量的意义

小样本容量
节省费用但
调查误差大

调查误差

样本容量

调查费用



找出在规定误差
范围内的最小样
本容量

找出在限定费用
范围内的最大样
本容量

大样本容量
调查精度高
但费用较大

二、估计均值时的样本容量

1、已知 σ^2 时， μ 的置信区间

$$[\bar{X} - \frac{\sigma}{\sqrt{n}} z_{\alpha/2}, \bar{X} + \frac{\sigma}{\sqrt{n}} z_{\alpha/2}]$$

$$\text{区间长度: } L = 2Z_{\alpha/2} \frac{\sigma}{\sqrt{n}}$$

在给定置信度 $1-\alpha$ 和区间长度可容许的上限值 l 都已经给定的前提下，要使 $L \leq l$ ，等价于

$$L = 2Z_{\alpha/2} \frac{\sigma}{\sqrt{n}} \leq l \rightarrow n \geq \left(\frac{2\sigma}{l} Z_{\alpha/2} \right)^2$$



例 在交通工程中需要测定车速（单位 km/h),由以往的经验知道，测量值为 X ， $X \sim N(\mu, \sigma^2)$ $\sigma^2 = 3.58^2$

1、至少作多少次观测，才能以0.99的可靠性保证平均测量值的误差在 ± 1 之间。

2、现在作了150次观测，试问平均测量值的误差在 ± 1 之间的概率有多大？

解 由题意知 $X \sim N(\mu, 3.58^2)$ 用平均测量值 \bar{X} 来估计 μ 其误差 $|\bar{X} - \mu|$ 由题意要求 $P\{|\bar{X} - \mu| < 1\} \geq 0.99$ $\alpha = 0.01$

由置信区间的概念，所求 μ 的0.99的 置信区间为

$$\left[\bar{X} \pm \frac{\sigma}{\sqrt{n}} z_{0.025} \right] \quad \text{即} \quad P\left\{ \left| \bar{X} - \mu \right| < \frac{\sigma}{\sqrt{n}} Z_{0.005} \right\} \geq 0.99$$

$$[\bar{X} \pm \frac{\sigma}{\sqrt{n}} z_{0.025}] \quad \text{即} \quad P\{|\bar{X} - \mu| < \frac{\sigma}{\sqrt{n}} Z_{0.005}\} \geq 0.99$$

$$\text{令} \quad \frac{\sigma}{\sqrt{n}} Z_{0.005} = 1 \quad \Rightarrow \quad n = 3.58^2 \cdot (2.576)^2 = 86.047$$

则钢索所能承受的平均张力为 6650.9 kg/cm^2


$$\therefore n = 86 \quad z_{0.005} = 2.57$$

至少要作86次观测，才能以0.99的可靠性保持平均测量误差在 ± 1 之间。

$$2. \quad n = 150 \quad \sigma = 3.58$$

$$P\{|\bar{X} - \mu| < 1\} = P\left\{\left|\frac{\bar{X} - \mu}{\frac{\sigma}{\sqrt{n}}}\right| < \frac{\sqrt{n}}{\sigma}\right\} = 2\Phi\left(\frac{\sqrt{n}}{\sigma}\right) - 1$$

$$= 2\Phi(3.421) - 1 = 2 \cdot 0.9997 - 1 = 0.9994$$



2、未知 σ^2 时, μ 的置信区间

$$\left[\bar{X} - \frac{S}{\sqrt{n}} t_{\alpha/2}(n-1), \bar{X} + \frac{S}{\sqrt{n}} t_{\alpha/2}(n-1) \right]$$

$$\text{区间长度: } L = 2 t_{\alpha/2}(n-1) \frac{s}{\sqrt{n}}$$

在给定置信度 $1-\alpha$ 和区间长度可容许的上限值 l 都已经给定的前提下, 要使 $L \leq l$, 等价于

$$L = 2 t_{\alpha/2}(n-1) \frac{s}{\sqrt{n}} \leq l$$

$$n \text{ 的下界依赖于 } s = \sqrt{\frac{1}{n-1} \sum_{i=1}^n (X_i - \bar{X})^2} \text{ 和 } t_{\alpha/2}(n-1)$$

-----Fisher问题

三、估计比率时的样本容量

1、设总体X服从(0-1)分布

$$P(X = k) = \theta^k (1 - \theta)^{1-k} \quad k = 0, 1$$

通常，未知参数 θ 的置信度为 $1 - \alpha$ 的置信区间近似为

$$\bar{X} \pm z_{\alpha/2} \sqrt{\bar{X}(1 - \bar{X})/n}$$

在给定置信度 $1 - \alpha$ 和区间长度可容许的上限值 l 都已经给定的前提下，要使 $L \leq l$ ，等价于

$$L = 2Z_{\alpha/2} \sqrt{\frac{\bar{x}(1 - \bar{x})}{n}} \leq l$$

$$\text{因此, } n \geq 4\bar{x}(1 - \bar{x}) \left(\frac{Z_{\alpha/2}}{l} \right)^2$$